



Höskolan
Kristianstad

Höskolan Kristianstad
291 88 Kristianstad
044-250 30 00
www.hkr.se

Examensarbete, 15 hp, för Kandidatexamen i Digital Design
VT 2026
Fakulteten för Ekonomi

Färg som designelement för att synliggöra hallucinationer i ChatGPT: En användarstudie inom hälsorelaterad självdagnostik

Naima Hassan, Rosie Zghaib & Rada Dubad

Författare

Naima Hassan, Rosie Zghaib & Rada Dubad

Titel

Färg som designelement för att synliggöra hallucinationer i ChatGPT: En användarstudie inom hälsorelaterad självdiagnostik

Engelsk titel

Color as a Design Element for Visualizing Hallucinations in ChatGPT: A User Study in Health Related Self-Diagnosis

Handledare

Kerstin Ådahl

Examinator

Mårten Pettersson

Sammanfattning

Large Language Models (LLMs) som ChatGPT används i hög grad för hälsorelaterade frågor och självdiagnostik, trots att de kan generera felaktig information med hög språklig säkerhet, ett fenomen som kallas hallucinationer. Detta riskerar att påverka användares hälsorelaterade beslut negativt, speciellt när användare okritiskt litar på AI-genererade svar, så kallad overreliance. Tidigare forskning har identifierat färg som ett lovande designelement för att synliggöra osäkerhet i AI-gränssnitt, men olika designvarianter har undersökts separat och ingen studie har jämfört flera varianter av färg specifikt i ChatGPTs gränssnitt i en hälsorelaterad kontext.

Denna studie undersöker hur olika sätt att implementera färg som designelement i ChatGPTs gränssnitt påverkar användares kritiska granskning av hälsorelaterade AI-genererade svar vid självdiagnostik, samt vilken designvariant användarna föredrar för att hjälpa identifiera hallucinationer och minska overreliance. Studien genomfördes med metoden forskning genom design och inkluderade kvalitativa djupintervjuer samt användartester av tre Figma-prototyper med sex deltagare i åldern 18-29 år utan medicinsk utbildning.

Intervjuerna visade att overreliance hos målgruppen är situationsbaserat snarare än ett fast beteende, och att medvetenhet om hallucinationer inte automatiskt leder till kritisk granskning. Användartesterna visade att de

olika designvarianterna ökade deltagarnas medvetenhet om osäker information och därmed minskade overreliance. Gränssnitt 3, som enbart markerade osäker information med röd färg, föredrogs av majoriteten av deltagare för sin tydlighet och läsbarhet. Flera deltagare föreslog att gult borde ersätta rött för att bättre kommunicera osäkerhet istället för direkt felaktighet. Studien bidrar med empiriskt underlag för hur färgvisualisering kan fungera som riskindikator i AI-gränssnitt och stödja kritisk granskning i en hälsorelaterad kontext.

Ämnesord

Hallucinationer, transparens, overreliance, large language models, hälsoinformation, gränssnittsdesign, färg

Author

Naima Hassan, Rosie Zghaib & Rada Dubad

Title

Color as a Design Element for Visualizing Hallucinations in ChatGPT: A User Study in Health Related Self-Diagnosis

Supervisor

Kerstin Ådahl

Examiner

Mårten Pettersson

Abstract

Large Language Models such as ChatGPT are widely used for health-related questions and self-diagnosis, despite being able to generate incorrect information with high linguistic confidence, a phenomenon known as hallucinations. This may negatively affect users' health-related decisions, particularly when users uncritically trust AI-generated responses, known as overreliance. Previous research has identified color as a promising design element for visualizing uncertainty in AI interfaces, but different design variants have been studied separately and none has compared multiple color variants in ChatGPT's interface in a health-related context.

This study examines how different ways of implementing color as a design element in ChatGPT's interface affect users' critical evaluation of health-related AI-generated responses during self-diagnosis and which design variant users prefer for identifying hallucinations and reducing overreliance. A research-through-design approach was used with qualitative interviews and user testing of three Figma prototypes involving six participants aged 18-29 without medical training.

Interviews showed that overreliance in the target group is situational rather than a fixed behavior, and that awareness of hallucinations does not necessarily lead to critical evaluation. User testing indicated that the design variants increased participants' awareness of uncertain information and reduced overreliance. Interface 3, highlighting only uncertain information in red, was preferred by the majority of participants for clarity and readability. Several participants suggested replacing red with yellow to better communicate uncertainty rather than direct false facts. The study provides

empirical evidence of how color visualization can function as a risk indicator in AI interfaces and support critical evaluation in a health-related context.

Keywords

Hallucinations, transparency, overreliance, large language models, health information, interface design, color

Innehållsförteckning

Begreppsdefinitioner.....	8
1. Introduktion.....	9
1.1 Problemformulering.....	10
1.2 Syfte och frågeställningar.....	11
2. Litteraturoversikt.....	11
2.1 Generativ AI och användning av ChatGPT.....	11
2.2 Hallucinationer och overreliance i LLM:er.....	12
2.3 Unga vuxnas användning av AI för hälsorelaterade frågor.....	13
2.4 Behovet av transparens i AI-gränssnitt.....	14
2.5 HILL - designelement för identifiering av hallucinationer i LLM:er.....	14
2.6 Designstrategier för färg.....	16
2.6.1 Användning av färgdimensioner vid visualisering av osäkerhet.....	16
2.6.2 Visuella markeringar för att kommunicera factuality i LLM-svar....	17
3. Metod och etik	20
3.1 Val av metod.....	20
3.2 Urval och deltagare.....	20
3.3 Förstudie.....	22
3.3.1 Teoretisk förstudie.....	22
3.3.2 Empirisk förstudie: kvalitativa djupintervjuer med användare.....	23
3.4 Prototypande.....	24
3.4.1 Val och avgränsning av designelementet färg.....	24
3.4.2 Prototyputveckling.....	25
3.4.3 Prompt och output.....	28
3.5 Genomförande av användartester.....	30
3.6 Analysmetod.....	31
3.7 Etik.....	31
3.8 Användning av AI.....	32
4. Resultat och analys.....	32
4.1 Intervjuresultat.....	32
4.1.1 Hälsorelaterad användning.....	32
4.1.2 Tillit och kritisk granskning.....	34
4.1.3 Medvetenhet om hallucinationer.....	37
4.1.4 Gränssnittet och transparens.....	38
4.1.5 Sammanfattning och analys av intervjuresultat.....	40
4.2 Prototyptestning.....	40
4.2.1 Gränssnitt 1.....	41
4.2.2 Gränssnitt 2.....	43

4.2.3 Gränssnitt 3.....	44
4.2.4 Sammanfattning.....	46
5. Diskussion.....	47
5.1 Resultatdiskussion.....	48
5.1.1 Intervjuresultat.....	48
5.1.2 Användartester.....	49
5.2 Metoddiskussion.....	52
6. Slutsatser.....	55
6.1. Fortsatt forskning.....	55
7. Efterord: deltagarnas bidrag.....	56
Referenser.....	57
Bilagor.....	62
BILAGA 1 - Intervjuguide.....	62

Begreppsdefinitioner

Designvariant

En specifik visuell utformning av ett designelement. I denna studie innebär designvariant olika sätt att implementera färg i ChatGPTs gränssnitt, där varje variant skiljer sig åt i hur färg används för att kommunicera osäkerhet.

Färg (designelement)

I denna studie är färg ett visuellt designelement som används för att synliggöra hallucinationer för användaren.

Färgkodning

I denna studie innebär färgkodning ett system där specifika färger används för att kommunicera olika grader av osäkerhet i AI-genererade svar.

Hallucination

När en LLM genererar faktamässigt felaktig information med hög språklig säkerhet.

Large Language Model (LLM)

AI-system som har tränats på stora textmängder för att generera mänskligt liknande svar.

Output

Det svar eller den text som ett AI-system genererar som svar på en användares fråga.

Overreliance

En överdriven tillit till AI-genererade svar utan kritisk granskning.

1. Introduktion

Generativ textbaserad artificiell intelligens (AI), så kallade *Large Language Models (LLM)*, är verktyg som tränas på stora mängder textbaserad data för att generera människoliknande svar. Dessa verktyg har snabbt integrerats i vardagen och erbjuder användare stöd i allt från informationssökning till beslutsfattande (Guo, Song, Chen, Han, Wu & Ma 2025; Shahsavar & Choudhury 2023). Specifikt har ChatGPT blivit ett av de mest använda AI-verktygen globalt och nådde över 100 miljoner användare redan i januari 2023 (Hu 2023).

Användning är särskilt hög inom hälsorelaterade frågor, där ett växande antal användare utan medicinsk bakgrund söker information om symtom och självdiagnostik via ChatGPT (Guo et al. 2025; OpenAI 2026; Shahsavar & Choudhury 2023). Nästan hälften av personer i åldern 18-29 år använder AI-verktyg regelbundet, och mer än en fjärdedel av ChatGPTs användare ställer hälsorelaterade frågor varje vecka (Cerino, Felts, Balmuth, Brennan, Lee & Coughlin 2025; Liu & Wang 2024; OpenAI 2026).

Denna utbredda användning innebär både möjligheter och risker. Även om verktyget kan ge snabb och lättillgänglig information har flera studier lyft oro kring att användare okritiskt litar på AI-genererade svar, trots att dessa kan innehålla felaktig eller fabricerad information, så kallade *hallucinationer* (Leiser, Eckhardt, Leuthe, Knaeble, Maedche, Schwabe & Sunyaev 2024; Shahsavar & Choudhury 2023; Zhao, Zhu, Han & Hu 2025). Detta kan exempelvis innebära att felaktiga medicinska råd ges eller att symtom feltolkas (Bhattacharyya, Miller, Bhattacharyya & Miller 2023).

På grund av sin stora roll som ett av de mest använda AI-verktygen globalt är ChatGPT därför relevant att undersöka i detta sammanhang. Detta väcker frågan om hur ChatGPTs gränssnitt kan utformas för att stödja användarens förmåga att kritiskt granska hälsorelaterade AI-genererade svar. Tidigare forskning pekar på att visuella designelement, såsom färg, kan kommunicera osäkerhet direkt i gränssnittet och därmed stödja kritisk granskning (Leiser et al. 2024; Reyes, Batmaz & Kersten-Oertel 2025). Med *färg* som designelement menas här hur färg

används i gränssnittet för att visuellt kommunicera graden av osäkerhet i AI-genererade svar. Hur olika *designvarianter* av färg, det vill säga specifika sätt att visuellt implementera färg i gränssnittet, påverkar användares kritiska granskning av hälsorelaterade AI-svar utgör utgångspunkten för denna studie.

1.1 Problemformulering

LLMs såsom ChatGPT genererar inte alltid korrekt information. Det föreligger en risk att modellen hallucinerar, samtidigt som felaktig information presenteras med hög språklig säkerhet. Detta kan påverka användarens uppfattning om informationens tillförlitlighet och därmed öka deras tillit till systemet (Guo et al. 2025; OpenAI 2026a). Forskning visar att svar och referenser som genererats av ChatGPT vid medicinsk rådgivning ofta är av låg kvalitet eller fabricerade, vilket kan resultera i allvarliga konsekvenser såsom felaktig självdiagnostik eller olämpliga behandlingsbeslut (Gravel, D'Amours-Gravel & Osmanliu 2023; Guo et al. 2025). Detta understryker att kritisk granskning av AI-genererad hälsoinformation är avgörande.

För att stödja användare i att identifiera hallucinationer har Leiser et al. (2024) tagit fram ett kompletterande externt verktyg, HILL (Hallucination Identifier for Large Language Models), till befintliga LLM:er, vilket inkluderar olika designelement. Färg har identifierats som ett effektivt designelement som kan användas för att signalera potentiellt felaktig information i ChatGPT. Däremot har endast en designvariant av färg undersökts (Leiser et al. 2024). Även om det finns etablerade designstrategier för hur färg kan användas för att kommunicera osäkerhet i LLM-gränssnitt genom exempelvis färgmättnad, nyans och ljusstyrka (Do et al. 2025), saknas fortfarande studier där dessa principer har tillämpats specifikt på ChatGPTs gränssnitt för att visualisera hallucinationer i hälsorelaterade svar. Detta lämnar ett behov av vidare forskning kring alternativa designvarianter av färg samt hur dessa påverkar användarens förmåga att identifiera hallucinationer i ChatGPT i en hälsorelaterad kontext.

1.2 Syfte och frågeställningar

Syftet med denna studie är att undersöka hur olika designvarianter av färg i ChatGPTs gränssnitt påverkar användares kritiska granskning av hälsorelaterade AI-svar vid självdiagnostik. Studien utvärderar vidare vilken designvariant som bäst stödjer identifiering av hallucinationer. Frågeställningar som studien avser att besvara är följande:

1. Hur påverkar olika sätt att implementera färg som designelement i ChatGPTs gränssnitt användarnas kritiska granskning av hälsorelaterade AI-genererade svar vid symtomsökning och självdiagnostik?
2. Vilken designvariant för färg föredrar användarna för att identifiera hallucinationer och minska overreliance på AI?

2. Litteraturoversikt

I detta kapitel presenteras tidigare forskning och bakgrund som är relevanta för studiens syfte. Först beskrivs ChatGPT och dess användning, följt av en genomgång av hallucinationer och overreliance i LLM samt ungas användning av AI för hälsorelaterade frågor. Därefter behandlas behovet av transparens i AI-gränssnitt och det befintliga verktyget HILL, som utgör studiens teoretiska utgångspunkt. Kapitlet avslutas med en genomgång av designstrategier för hur färg kan användas för att visualisera osäkerhet i gränssnitt.

2.1 Generativ AI och användning av ChatGPT

En global trafikdata visar att ChatGPT var ett av de mest besökta AI-verktygen under år 2024 med 82% av det totala antalet besök bland AI-verktyg (Liu & Wang 2024). Verktöget har därmed blivit ett av de mest spridda generativa AI-systemen globalt. Ett annat nytt verktyg, ChatGPT Health, lanserades januari 2026 i USA men är ännu inte tillgängligt globalt, där användare kan koppla sina medicinska

journaler och hälsoappar för att få mer personliga och kontextuella svar. Verktöget är utformat för att stödja medicinsk vård och används specifikt för hälsorelaterade frågor (OpenAI 2026b). Som standard fungerar ChatGPT genom att ge svar som baseras på sin egen träningsdata snarare än att basera informationen på sökning av källor och redovisa det (OpenAI 2026a). Även när ChatGPT uppmanas i prompten att visa källor visar forskning att en stor majoritet av de genererade referenserna är fabricerade eller felaktiga, vilket gör källhänvisningar till en otillförlitlig grund för informationens korrekthet (Bhattacharyya et al. 2023). OpenAI (2026a) har däremot nyligen introducerat ett verktyg, Deep Search och Web Search, som möjliggör källhänvisningar baserade på realtidssökning, men dessa måste aktiveras aktivt av användaren och är inte tillgängliga som standard. Till skillnad från ChatGPT använder andra LLM såsom Perplexity AI information från internet i realtid, vilket gör det möjligt att ge uppdaterade svar utan att användaren behöver aktivera detta manuellt (Perplexity Team 2023).

2.2 Hallucinationer och overreliance i LLM:er

ChatGPT kan generera textbaserade svar och visa god prestation på uppgifter även utan specifik träning, vilket bidrar till att systemen upplevs som kompetenta och självsäkra. Eftersom LLMs tränas genom att förutsäga sannolika svar i stället för att verifiera fakta, kan de generera språkligt övertygande men faktamässigt felaktiga svar. Dessa fenomen benämns inom forskningen som hallucinationer, där systemet presenterar osäkra eller påhittade uppgifter med hög språklig säkerhet (Leiser et al. 2024; OpenAI 2026a; Zhao, Zhu, Han & Hu 2025). Hallucination kan förklaras av hur modeller tränas: i stället för att kontrollera fakta mot en källa genererar modellen nästa ord baserat på vad som statistiskt verkar rimligt utifrån tidigare träningsdata. Detta innebär att systemet kan presentera felaktig information med hög språklig säkerhet utan att signalera osäkerhet för användaren (Ji, Lee, Frieske, Yu, Su, Xu, Ishii, Bang, Madotto & Fung 2023).

Samtidigt har tidigare forskning visat att användare tenderar att utveckla en överdriven tillit till AI-system, så kallad *overreliance*, där svar accepteras utan kritisk granskning (Leiser et al. 2024; Zhao, Zhu, Han & Hu 2025). Studier inom Human-Computer Interaction (HCI) visar att detta sker eftersom användare sällan

granskar varje AI svar kritiskt, men i stället utvecklar generella heuristiker, alltså mentala tumregler om att systemet är tillförlitligt, och kan därför acceptera svar utan att kombinera dem med deras egna insikter även när svaren är felaktiga (Buccinca et al. 2021; Zhao et al. 2025). Forskning påpekar dock att dessa mönster behöver undersökas vidare i olika kontexter och domäner, särskilt i sammanhang där konsekvenserna av okritisk tillit kan vara allvarliga (Buccinca et al. 2021). Detta är speciellt relevant i hälsorelaterade sammanhang, där felaktig AI-genererad information direkt kan påverka användares beslut om vård och behandling.

2.3 Unga vuxnas användning av AI för hälsorelaterade frågor

Liu & Wang (2024) visar att användning av generativ AI är särskilt utbredd bland yngre vuxna. Statistik visar att över hälften av 16-24 åringar (67%) och 25-34 åringar (58%) använder AI-verktyg regelbundet, medan betydligt färre äldre användare rapporterar samma användningsnivå och uppvisar lägre tilltro till tekniken (Cerino et al. 2025). ChatGPT används även i hög grad av högutbildade användare, där personer i åldern 18-29 år utgör en stor andel av användargruppen (Liu & Wang 2024). Yngre vuxna är därmed en central användargrupp för generativ AI och blir en relevant målgrupp för studier som undersöker hur användare interagerar med AI-baserade system.

Forskning visar att ett växande antal användare utan medicinsk bakgrund använder ChatGPT för att söka hälsorelaterad information och medicinska råd (Guo et al. 2025; Shahsavar & Choudhury 2023). Shahsavar och Choudhury (2023) identifierar flera faktorer som bidrar till den höga användning: verktyget är lättillgängligt och kostnadsfritt, erbjuder anonymitet vid känsliga frågor och ger direkta svar utan behov av läkarbesök. Att 78,4% av deras deltagare var villiga att använda ChatGPT för självdiagnostik visar hur utbredd denna användning är och varför målgruppen är relevant för denna studie.

2.4 Behovet av transparens i AI-gränssnitt

Eftersom generativa AI-system, såsom ChatGPT, allt oftare används i kontexter där felaktig information kan få allvarliga konsekvenser, exempelvis vid hälsorelaterad information och självdiagnostik, blir transparens i AI-gränssnittet en central designfråga (Liao & Vaughan 2023; Guo et al. 2025). Transparens i denna kontext innebär att systemet tydliggör graden av modellens osäkerhet i svaren och grunderna för hur ett svar genereras. Ett AI-system som kommunicerar sin osäkerhet möjliggör för användaren att snabbt anpassa sin tillit till systemets svar och bilda sig en uppfattning om dess förmågor och begränsningar (Liao & Vaughan 2024).

Forskning visar att användares tillit till generativ AI påverkas av flera faktorer, där både systemets transparens och den upplevda kvaliteten på informationen spelar en viktig roll (Guo et al. 2025; Shahsavar & Choudhury 2023). Enbart förklaringar i AI-gränssnittet är inte tillräckligt för att minska overreliance, det krävs designlösningar som stödjer användaren aktivt i att tänka analytiskt kring de genererade svaren (Buccinca et al. 2021). Detta understryker behovet av designelement som direkt synliggör osäkerhet i gränssnittet. Visualisering av osäkerhet genom bland annat användning av färg kan öka tillit till AI. Vidare kan även kommunikation av designelement öka transparens av AI och tillförlitlighet hos användare som interagerar med LLM-genererade svar (Do, Ostrand, Geyer, Murugesan, Wei & Weisz 2025; Reyes et al. 2025). Genom att synliggöra dessa aspekter kan ett transparent gränssnitt stödja användare i att själva kunna kritiskt granska AI-genererad information (Liao & Vaughan 2024).

2.5 HILL - designelement för identifiering av hallucinationer i LLM:er

HILL är ett kompletterande verktyg för befintliga LLM:er, såsom ChatGPT, som har visat sig underlätta identifiering och synliggörande av hallucinationer i AI-genererade svar (Leiser et al. 2024). Detta möjliggörs genom användning av olika designelement som tydliggör potentiella hallucinationer för användaren. I

studien vid framtagningen av HILL benämndes designelement som funktioner. För att upprätthålla ett konsekvent språk i denna studie kommer begreppet designelement istället att användas.

HILL-verktyget utvecklades med fokus på en användarcentrerad designprocess för att identifiera användarbehov och relevanta designelement. Designelementen grupperades i olika kategorier med liknande funktionalitet men olika visuella presentationer (se tabell 1). Dessa implementerades och testades i tre prototyper utformade efter ChatGPT:s gränssnitt, där Group 1, 2 och 3 i tabellen motsvarar de olika prototyperna. Varje prototyp bestod av en unik kombination av designelement och utformades för att stimulera en specifik prompt, i syfte att undersöka vilka designelement inom respektive kategori som presterade bäst.

Category	Group 1	Group 2	Group 3
Confidence Score	Colored Ordinal CS	Ordinal CS	Metric CS
Sources	Source Links (Drill-Down), Source Quality	Direct Quotes	Source Links (Pop-up), Source Quantity
Disclosure	Monetary Interest	Disclaimer	Political Spectrum, Ethical & Legal Consid.
Visual Aid	Response Type	-	Color
In Text	Explanations	Phrasing	-
Customization	Replies	Confidence Threshold	Drill-down Dashboard

Tabell 1: Översikt över alla designelement fördelade mellan de tre prototyperna (Leiser et al. 2024)

HILL-gränssnittet inkluderar de designelement som identifierats som mest betydelsefulla för att synliggöra potentiella hallucinationer i LLM:er. Gränssnittet har visat sig stödja användarens kritiska granskning av AI-genererade svar. Fem designelement bedömdes som betydelsefulla, varav färg i form av färgmarkering är ett av dessa (Leiser et al. 2024). Denna studie avgränsas till detta designelement.

Trots HILLs styrkor påpekar Leiser et al. (2024) att verktyget har vissa begränsningar. Författarna (Leiser et al. 2024) konstaterar att de för de flesta designelement endast utvecklade en enda designvariant, vilket innebär att den visuella representationen av varje element lämnades utanför studiens omfattning.

De understryker vidare att alternativa varianter i framtida studier potentiellt kan förbättra användarens interaktion med verktyget:

“[...] we developed only one instantiation for most of the proposed design features. [...] it leaves the representation of each feature out of scope. In future studies, different instantiations might further improve the interaction with the system.” (Leiser et al. 2024, s.13)

Mot denna bakgrund identifieras en forskningslucka kring hur alternativa designvarianter av samma designelement påverkar användarens förmåga att upptäcka hallucinationer. För att möjliggöra en fördjupad analys av denna lucka avgränsas denna studie till designelementet färg, där endast en designvariant av färgmarkering tidigare har undersökts (Leiser et al. 2024). Denna studie fokuserar därmed på att ta fram olika designvarianter av färg och undersöka hur dessa upplevs av användare i ChatGPT:s gränssnitt, till skillnad från det komplementerande HILL- verktyg.

2.6 Designstrategier för färg


Nedan presenteras befintliga och relevanta designstrategier som kan användas som riktlinjer för att skapa olika designvarianter av färg för att synliggöra hallucinationer.

2.6.1 Användning av färgdimensioner vid visualisering av osäkerhet

För att visualisera osäkerhet har tidigare studier föreslagit tre huvudsakliga typer av visuella variabler, varav färgbaserade tekniker utgör en av dessa (Boukhelifa, Bezerianos, Isenberg & Fekete 2012; Reyes et al. 2025). Färgbaserade tekniker innebär att färg utnyttjas för att skildra osäkerheten, till exempelvis genom färgdimensioner såsom nyans, ljusstyrka eller mättnad. Av de olika färgdimensionerna föredras mättnad, eftersom dämpad färg intuitivt förknippas med mindre pålitlig information (Boukhelifa et al. 2012). Färgnyanser, särskilt regnbågsfärger, används också för att visa olika nivåer av osäkerhet. Färgens ljusstyrka kan även skildra säkerhet och osäkerhet, där mörkare kontrast förmedlar högre säkerhet, medan lägre kontrast signalerar lägre säkerhet. Genom

att tillämpa dessa strategier för färg skapas förutsättningar för att utveckla olika designvarianter för färg i ChatGPTs gränssnitt.

Armstrong et al. (2025) har genomfört ett explorativt och interdisciplinära projekt med syfte att förse vägledning, förklaring och transparens genom att designa AI-gränssnitt som tar hänsyn till osäkerhet i LLM-genererade svar. Studien resulterade i ett valideringssystem (MAVS) för LLM bestående av interaktiva gränssnitt och prototyper, där olika sätt att visualisera osäkerhet testades. Färg utgjorde ett centralt designelement och användes i kombination med andra visuella uttryck för att kommunicera osäkerhet. Detta inkluderade användning av färgdimensioner såsom mättnad och intensitet, samt visuella element såsom genomstrykning, mönster, suddighet och volym (se figur 1).




Figur 1: Åtta visuella element vars syfte är att visualisera osäkerhet LLM svarstext (Armstrong et al. 2025)

2.6.2 Visuella markeringar för att kommunicera factuality i LLM-svar

Do et al. (2025) undersökte den mest effektiva designvariant av färg för att visualisera korrektheten och osäkerheten hos svar från LLM för att underlätta bedömning av trovärdigheten hos innehållet. Studien syftade bland annat till att undersöka vilken designvariant av färg som möjliggör validering av information och vilken design som är mest föredragen bland deltagarna i studien.

Deltagarna introducerades att föreställa sig att de använde LLM och fick ta del av en enkel icke-teknisk fråga, tillhörande svarstext bestående av både korrekt och felaktig information. Informationen var motsägelsefull i förhållande till textreferenser som deltagarna fick betraktas som trovärdig. Olika designvarianter av färg tillämpades på samma information i fråga, svarstext och referens. Deltagarna fick först testa en design som inte innehöll någon färgmarkering i texten. Därefter introducerades en factuality score, ett värde som anger graden av hur korrekt fakta är i svaret genom att jämföra språkliga delar av svaret med referensen. En hög factuality score indikerade att svaret är förenligt med informationen från referensen och därmed är sannolikt korrekt (Do et al. 2025).

Sex designstrategier presenterades för att visualisera information om faktakorrekthet. Dessa bestod av tre designvarianter som tillämpades på två nivåer (term- och frasnivå). Designvarianter inkorporerade en *färgkodning* som visar factuality score för varje enskilt ord i svarstexten, på en skala från låg till hög factuality (0-1) (se figur 2).



Figur 2: En skala som genom färg och numeriska värden visar factuality score (Do et al. 2025)

Designvarianter utformades för att visualisera factuality i svarstexten på följande tre sätt (se figur 3):

- Highlight-all: Hela svarstexten färgmarkeras och varje del i texten markerades med en färg motsvarande dess factuality score.
- Highlight-threshold: Endast de sektioner i svarstexten med en factuality score lägre än 0.5 färgmarkerades för att signalera felaktigheter.

3. Metod och etik

I detta kapitel redogörs för studiens metodologiska tillvägagångssätt och de etiska överväganden som tas till hänsyn. Kapitlet inleds med en beskrivning av den övergripande metodansatsen, följt av urval och deltagare, förstudie, prototyputveckling, genomförande av användartester och etik. Avslutningsvis redogörs för studiens användning av AI-verktyg.

3.1 Val av metod

Metoden som tillämpades är en kvalitativ ansats där empiri insamlats för att få en djupare förståelse kring studiens syfte och frågeställningar. Vidare användes *forskning genom design* som är en etablerad metod inom HCI och designforskning (Löwgren 2015; Zimmerman, Forlizzi & Evenson 2007). Metoden valdes eftersom studiens syfte var att undersöka hur olika designvarianter av färg i ChatGPTs gränssnitt påverkar målgruppens kritiska granskning av AI-genererade hälsosvar vid självdiagnostik samt att utvärdera vilken designvariant som föredrogs vid identifiering av hallucinationer. Metoden skapade förutsättningar för att generera ny kunskap genom designprocessen, vilket omfattade omvärldsbevakning, litteraturundersökning, kvalitativa djupintervjuer, prototypframtagning och användartester. Designprocessen tillför ett kunskapsbidrag genom utformning, jämförelse och utvärdering av olika designvarianter tillsammans med användare, vilket gav insikter om hur olika färgmarkeringar påverkar identifieringen av hallucinationer och overreliance i AI-svar. Prototyperna användes därmed både som forskningsverktyg och designförslag för att besvara studiens frågeställningar.

3.2 Urval och deltagare

Sex deltagare inkluderades i studien genom ett bekvämlighetsurval (Patel & Davidson 2019). Deltagare i studien har inkluderats genom urvalskriterier som är unga vuxna mellan 18-29 år som inte har någon medicinsk utbildning, har erfarenhet av att använda sig av ChatGPT för att söka information om symptom

och självdiagnostik. Målgruppens ålder har begränsats till 18-29 år eftersom Liu & Wang (2024) påvisar att denna åldersgrupp använder sig mest av ChatGPT. Begränsningen stöds även av Cerino et al. (2025) som identifierar unga vuxna som en målgrupp med hög AI-användning. Vidare är deltagarna i åldersgruppen myndiga och inkluderas i studien eftersom de säkerställer möjligheten till ett frivilligt och informerat samtycke vilket är förenligt med Lag (2003:460) om etikprövning av forskning som avser människor (Sveriges riksdag 2003, 18§). Eftersom studiens syfte är att förstå hur olika designvarianter av färg som designelement i ChatGPTs gränssnitt påverkar användares kritiska granskning av hälsorelaterade AI-genererade svar vid självdiagnostik, inkluderades endast deltagare som har erfarenhet av att använda sig av verktyget ChatGPT för att söka information om symtom och självdiagnostik. För att resultatet inte ska snedvridas får deltagarna inte ha någon medicinsk utbildning, eftersom det har en koppling till individens förmåga att förstå, förvärva och använda hälsoinformation. Sådan kunskap kan därför påverka förmågan att kritiskt granska informationen (World Health Organization 2025).

Urvalskriterierna sammanfattas nedan:

- Vuxna (18-29 år)
- Erfarenhet av att använda ChatGPT
- Använder ChatGPT för att söka om symtom och få självdiagnostik
- Ingen medicinsk utbildning

För att öka läsbarheten och bevara anonymiteten har deltagarna tilldelats fiktiva namn. I intervjuerna benämns de som respondenter, medan begreppet deltagare används genomgående för samma personer i studien som helhet. Dessa namn har ingen koppling till respondenternas verkliga identitet förutom könet som återspeglas i namnen. En översikt över studiens respondenter presenteras i tabell 2 nedan.

Respondent	Ålder	Sysselsättning	Användningsfrekvens (Hälsa)
Sara	23	Barnskötare/elevassistent	Dagligen
Karl	18	Gymnasiestudent	4-5 gånger/vecka
Erik	18	Gymnasiestudent	1-2 gånger/månad
Lina	28	Ekonomistudent	1-2 gånger/månad
Anna	25	Revisor	Varannan/var tredje dag
Johan	21	Högskolestudent	1 gång/vecka

Tabell 2: Respondenternas demografiska data och användningsfrekvens

3.3 Förstudie

3.3.1 Teoretisk förstudie

Den teoretiska förstudien innefattar genomförandet av en omvärldsanalys för att systematiskt samla in, analysera och skapa förståelse för den omgivande kontexten och problematiken som berör ämnesområdet i studien. Detta utfördes genom litteraturundersökningar där tidigare relevant forskning för studien utforskades. Sökningar genomfördes främst i databaserna ACM, PubMed och Researchgate, vilket valdes eftersom databaserna innehåller forskning inom HCI, medicin samt digital hälsoteknik som har en relevans för studiens ämnesområde. Sökresultaten omfattade relevanta artiklar som till stor del var publicerade mellan åren 2020 och 2026. Undantag var artikeln av Boukhelifa et al. (2012) som inkluderades på grund av dess relevans till arbetet och eftersom informationen stöds av senare forskning (Reyes et al. 2025). Fokus låg på att inkludera

vetenskapliga artiklar som är peer-reviewed för att säkerställa att källorna som tillämpats i studien innehåller en god kvalitet och standard (Karolinska Institutet Universitetsbiblioteket, u.å.). Artiklarna gick igenom tidskriftsregistret HKDIR (u.å.) för att säkerställa att de var peer-reviewed. En kombination av booleska operatorer och nyckelord användes för att hitta relevanta artiklar. Följande söksträngar är några exempel som användes vid litteratursökning:

- "Chatgpt" AND "health information" AND "trust"
- ("AI" OR "Large Language Models" OR "ChatGPT") AND "hallucination"
- "overreliance" AND ("AI" OR "Large Language Models" OR "ChatGPT") AND "interface"
- ("AI" OR "Large language models" OR "ChatGPT") AND "Hallucination" AND "Identifier"

Vidare användes fördjupade sökmetoder genom kedjesökning och citeringar för att komplettera litteraturunderlaget med andra relevanta källor (Göteborgs universitet, u.å.; Umeå universitet, u.å.). HILL-studien (Leiser et al. 2024) användes som utgångspunkt för att identifiera ytterligare relevanta artiklar inom forskningsområdet.

3.3.2 Empirisk förstudie: kvalitativa djupintervjuer med användare

Den empiriska förstudien innefattade en explorativ studie baserad på kvalitativa djupintervjuer med frågor om användning, tillit och designpreferenser. Då frågorna inte var direkt kopplade till studiens specifika forskningsfrågor bidrog intervjuerna främst till att skapa en grund för forskningsfrågorna inom studiens målgrupp. De syftade till att ge en förståelse för målgruppens beteende och behov, samt att identifiera deras preferenser när det gäller designelement för att möjligtvis motivera studiens designval. Intervjuerna hade därför rollen som både förstudie och empiriska underlag för att förstå kontexten inom vår målgrupp samt ge underlag för designval i prototyputvecklingen.

Djupintervjuerna strukturerades utifrån Tjoras (2012) rekommendationer om intervjuens tre faser: uppvärmning, reflexion och avrundning, där uppvärmningsfrågor skapar trygghet, reflexionsfrågor formar kärnan i intervjun genom öppna frågor, och avrundningsfrågor normaliserar situationen och avslutar samtalet (se Bilaga 1). Reflexionsfrågorna utformades utifrån fyra identifierade teman: hälsorelaterad användning, tillit och kritisk granskning, medvetenhet om hallucinationer samt gränssnittet och transparens. Temana baserades på studiens syfte och frågeställningar och låg till grund för datainsamlingen.

Sex intervjuer genomfördes, vardera om cirka 20 minuter. Intervjuerna skedde antingen fysiskt med respektive deltagare i deras hem eller digitalt via Zoom där de befann sig i sitt hem. Syftet var att skapa en avslappnad ställning där deltagarna kände sig bekväma med att dela sina faktiska upplevelser och åsikter. Deltagarna informerades dessutom om att det inte fanns rätt eller fel svar och att deras ärliga reaktioner var det som efterfrågades. Respondenter som intervjuades digitalt var Anna och Johan och de resterande deltagarna intervjuades fysiskt.

För att säkerställa att all relevant information dokumenterades spelades intervjuerna in och kompletterades med anteckningar. Intervjumaterialet transkriberades och renskrevs sedan för att utesluta tal- och fyllnadsord i syfte att underlätta läsning och analys utan att påverka det som sagts. Därefter analyserades materialet med kvalitativ tematisk analys (Tjora 2012), där innehållet systematiskt kodades och sorterades utifrån de fyra teman som strukturerade intervjuerna. Inom varje tema identifierades återkommande mönster och olika svar, vilket möjliggjorde både en övergripande bild av målgruppens attityd mot verktyget och en djupare förståelse för individuella skillnader mellan respondenterna. Resultaten presenteras i enlighet med denna tematiska struktur i avsnitt 4.1.

3.4 Prototypande

3.4.1 Val och avgränsning av designelementet färg

Studien avgränsas till hur ChatGPTs gränssnitt kan stödja användaren att upptäcka hallucinationer efter att *output* (svar) har genererats. Utifrån denna avgränsning exkluderades fyra av de fem designelement som HILL identifierade som mest betydelsefulla för att identifiera potentiella hallucinationer (Leiser et al. 2024).

Confidence threshold, ett tröskelvärde för säkerhetsnivå, exkluderades av två anledningar. Först anpassas designelementet *innan* ett svar genereras genom att användaren väljer säkerhetsnivå för modellens svar, vilket innebär att den faller utanför studiens avgränsning. Dessutom påpekar Leiser et al. (2024) specifikt att designelementet inte kunde implementeras i HILL på grund av det var oklart hur den skulle implementeras tekniskt. Därmed gäller samma begränsning även för en Figma-baserad prototyp.

Metric CS, ett säkerhetspoäng där AI:n uppskattar tillförlitlighet i sitt svar, exkluderades eftersom det är den enda kategori där HILL redan testade flera designvarianter: ordinal CS (säkerheten visualiseras i nivåer), colored ordinal CS (säkerheten visualiseras i nivåer med kombination av färg) och metric CS, och där metric CS visades vara mest effektiv. Designutrymmet för designelement är därför mer utforskat jämfört med övriga designelement, vilket gör det mindre relevant att undersöka vidare i denna studie.

Monetary interest exkluderades eftersom elementet syftar till att identifiera ekonomiska intressen bakom ett svar, exempelvis betalt innehåll. I denna kontext av hälsorelaterade frågor till ChatGPT är detta inte en relevant faktor.

Source links, presentation av källor, exkluderades eftersom designelementet främst möjliggöra verifiering av information via externa källor i stället för att visualisera modellens osäkerhet direkt i gränssnittet, vilket är studiens fokus.

Färg kvarstår därför som det mest lämpliga designelementet att undersöka vidare inom ramen för denna studie.


3.4.2 Prototyputveckling

Figma användes som designverktyg vid framtagningen av prototyperna. Först skapades ett gränssnitt som efterliknade ChatGPT:gränssnitt för att skapa en så verklighetstrogen interaktion som möjlig. Detta gjordes genom att inkludera en ljus bakgrund och använda skärmdumpar av ikonerna och logotypen från ChatGPT. Grundgränssnittet kopierades för att skapa tre gränssnitt som testar olika designvarianter. Low-fidelity skisser skapades för att utforska utformningen av sidoinformationen bredvid outputen i syfte att stödja användaren i att förstå gränssnitten.

Gränssnitten bestod av ett gemensamt simulerat gränssnitt av ChatGPT som innehöll en förutbestämt prompt och relaterad output i relation till studien, samt tre olika designvarianter för färg. Designvarianterna utformades med utgångspunkt i tidigare forskning och designstrategier kring hur färg kan användas för att visualisera osäkerhet i information (Boukhelifa et al. 2012; Do et al. 2025; Leiser et al. (2024); & Reyes et al. 2025), samt utifrån den insamlade empiriska datan från deltagarnas djupintervjuer.

Designprocessen resulterade i tre interaktiva prototyper med ett gemensamt gränssnitt som simulerade ChatGPT samt en standardiserad prompt och svar. Prototyperna skilde sig åt genom tre olika designvarianter av färg. I samtliga prototyper benämndes potentiellt hallucinerad information som “information som är osäker” i syfte att göra begreppet mer lättförståeligt för användaren samt eftersom benämningen ska vara mer tekniskt korrekt.

Gränssnitt 1



Figur 4: Gränssnitt 1 - Röd och grön färgmarkering av text


Det första gränssnittet (se Figur 4) byggde på designstrategin Highlighted ALL (Do et al. 2025), där hela svarstexten färgmarkerades utifrån informationsstatus. Genom användning av färgnyans och hög mättnad (Boukhelifa et al. 2012; Reyes et al. 2025) tilldelades varje fras en färg som representerar dess status baserat på färgkodningen:

- Röd: representerade information som är osäker.
- Grön: representerade information med hög tillförlitlighet.

Dessa färgval baserades både på resultaten från Do et al. (2025) och intervjuerna, där respondenterna efterfrågade dessa färgskillnader. Gul färg uteslöts från färgkodningen för att minska risk för tolkningssvårigheter och skapa en tydligare distinktion mellan osäker information och tillförlitlig information.

Syftet med designvarianten var att undersöka hur en fullständig kodning av hela svaret påverkade bedömningen av svarets trovärdighet i en hälsorelaterad kontext.

Gränssnitt 2




Figur 5: Gränssnitt 2 - Hög och låg färgmättnad av svart text

Det andra gränssnittet (se Figur 5) baseras på användning av svart text där färgmättnaden justerades för att visualisera informationens status (Boukhelifa et al. 2012). Osäker information representerades med låg färgmättnad och framträdde i en mer gråtonad nyans, medan information med hög tillförlitlighet visualiserades med hög färgmättnad och därmed en högre kontrast mot bakgrunden. Syftet med det svarta färgvalet var att undersöka användarnas upplevelse av ett mindre färgstarkt gränssnitt.

Denna designvariant syftade till att undersöka hur färgmättnad kan utnyttjas för att signalera potentiell hallucinerad information.

Gränssnitt 3



Figur 6: Gränssnitt 3 - Röd färgmarkering av text

Det tredje gränssnittet (se Figur 6) utgick från selektivt färgmarkering inspirerad av Do et al. (2025) och deras strategi highlight threshold. I gränssnittet

markerades endast osäker information med röd färg, medan information med hög tillförlitlighet förblev oförändrad.

Designvarianten var avsedd att undersöka hur endast färgmarkering av potentiellt hallucinerad information påverkade användarens förmåga att kritiskt granska svaret.

De tre olika designvarianterna av färg utformades i respektive gränssnitt för att kunna undersöka hur valda designvarianter påverkar användarnas kritiska granskning, men också för att undersöka vilken designvariant som upplevdes mest effektiv för att identifiera hallucinationer och minska overreliance av AI.

3.4.3 Prompt och output

Vid utformning av promptar rekommenderas att de är specifika, tydligt formulerade och fokuserade på relevanta ämnesord, för att undvika att vaga eller öppna promptar genererar inkonsistenta eller alltför generiska svar (Boonstra 2025; Liu & Chilton 2022). Därför är prompten i gränssnittet förutbestämd och utformad av författarna utifrån ett specifikt hälsorelaterat ämne som deltagaren får välja mellan vid test av prototyperna. Anledningen till att prompten utformades av författarna är att minska eventuella olikheter i hur deltagarna formulerar sina frågor så att resultatet inte påverkas av variationer i frågeformulering utan enbart av de designlösningar som är utformade i gränssnittet. Prompten utformades enligt principerna för kontextuell prompting (Boonstra 2025) där den bör innehålla:

1. Bakgrundsinformation såsom ålder, kön och sysselsättning
2. Detaljerad symtom med tidsangivelse
3. Ämnesspecifika instruktioner
4. Avslutande direkta frågor

Den förutbestämda prompten som används i samtliga tre prototyper är följande:

“De senaste tre veckorna har jag haft svårt att somna. Jag ligger vaken i minst en till två timmar varje kväll trots att jag är trött. När

jag väl somnar vaknar jag ofta upp mitt i natten och har svårt att somna om. På dagarna känner jag mig konstant utmattad, har svårt att koncentrera mig på föreläsningar och känner mig lite yr ibland. Jag dricker kaffe på morgonen men inte på kvällen. Kan det vara något allvarligt? Vad kan det bero på och vad kan jag göra?”

Bakgrundsinformation uteslöts för att skapa en så personlig upplevelse som möjligt för användarna som testade prototypen. Samma prompt användes i alla gränssnittsdesign för att säkerställa att deltagarnas reaktioner och bedömningar enbart speglar skillnader i designvariant och inte i frågans innehåll eller formulering.

Outputen som används i samtliga tre prototyper följer ett verkligt ChatGPT genererat svar på prompten, men har redigerats för att minska mängden text och säkerställa en kontrollerad fördelning av korrekt och felaktig information. Denna metod följer Do et al. (2025) som använde samma sätt för att möjliggöra kontrollerad utvärdering av designelementets förmåga att visualisera felaktig information.

Outputen innehåller flera medicinskt korrekta påståenden och två medvetet felaktiga påståenden, så kallade hallucinationer. De korrekta påståendena är bekräftade av 1177 (2023), Sveriges officiella vårdguide. De felaktiga påståendena är utformade för att vara subtila och realistiska, alltså språkligt trovärdiga men faktamässigt felaktiga, i linje med hur verkliga hallucinationer i LLM svar vanligtvis ser ut (Ji et al. 2023).

De två medvetet felaktiga påståendena är följande: att man bör gå upp ur sängen efter 30–45 minuter om man inte somnat, vilket överstiger 1177:s rekommendation om 15 minuter, samt att koffein inte bör tas senare än två timmar innan läggdags, vilket understiger 1177:s rekommendation om sex timmar. Alla deltagare informerades genom gränssnittets sidopanel om förekomsten av felaktig information i outputen.

3.5 Genomförande av användartester

Vid användartester genomfördes think-aloud i kombination med observationer (Martin & Hanington 2016) medan deltagarna interagerade och testade de olika gränssnitten i Figma-prototyperna. Användartesterna genomfördes med samma sex deltagare som intervjuades. Dessa utfördes, som i avsnitt 3.3.2, antingen fysiskt i deras hem eller digitalt via Zoom och varade cirka 15-20 minuter. Vid fysiska tester kunde deltagarna visa sin skärm direkt med testledaren, medan deltagarna vid digitala tester delade sin skärm via Zoom medan videokameran var på, vilket möjliggjorde att testledaren kunde följa interaktionen och reaktioner. Samtliga deltagare fick innan användartestning av prototyperna information om prompten i gränssnittet. De fick instruktionen att föreställa sig att prompten var utformad av dem själva och att information om de valda hälsorelaterade ämnet eftersöktes samt att tänka högt. Varje deltagare testade samtliga gränssnitt individuellt, där gränssnitt 1 testades först och gränssnitt 3 sist. När deltagarna testade gränssnitten och beskrev sina tankar fritt ställdes huvudfrågor samt följdfrågor för att styra användartesterna i kopplat till studiens frågeställningar. Exempel på frågor som ställdes var:

- Vad är det som gör att det blir tydligt med färgen?
- Känner du att du har blivit uppmärksammas på osäker information?
- Skulle du gå vidare och granska informationen, eller nöjer du dig med det du fått?

Observationerna dokumenterades genom inspelning och anteckningar. Syftet med observationerna var att fånga hur deltagarna agerar i mötet med de olika gränssnitten hos prototyperna, det vill säga beteenden och reaktioner som kan vara svåra för deltagarna att verbalisera, och därmed bidra till att besvara studiens frågeställningar (Benyon 2019). Det insamlade materialet transkriberades och renskrevs genom exkludering av tal- och fyllningsmaterial. Därefter analyserades materialet tematiskt utifrån tre teman: läsbarhet och visuell tydlighet, förståelse av färgens kommunikativa funktion samt påverkan på kritisk granskning. Inom dessa

teman identifierades både återkommande och skillnader i deltagarnas upplevelser och svar för respektive prototyp.

3.6 Analysmetod

Efter datainsamlingen transkriberades och renskrevs det insamlade materialet. Analysen genomfördes som en tematisk analys med en induktiv ansats (Tjora 2012), där centrala mönster och upplevelser kring gränssnittet identifierades. Bland annat genomfördes identifiering av upprepade kodord och uttryck, samt beteende i deltagarnas svar. Materialet analyserades i flera omgångar för att fånga både liknande och varierande reflektioner kopplade till studiens frågeställningar.

3.7 Etik

Under studiens gång beaktades etiska överväganden, där målet har varit att följa god forskningssed, definierad som de forskningsetiska krav och den praxis som uppstår när dessa krav följs (Vetenskapsrådet 2024). I enlighet med vetenskapsrådet (2024) riktlinjer har studien tagit hänsyn till ALLEA-kodexens grundprinciper: Tillförlitlighet, Ärlighet, Respekt, Ansvar samt de ”fyra principerna”: att göra gott, att inte skada, att respektera självbestämmande, att upprätthålla rättvisa.

Samtliga deltagare informerades om studiens syfte, det frivilliga deltagandet samt hur konfidentialitet och personuppgifter hanterades. Deltagarna gav informerat samtycke till deltagande samt till inspelning och anteckningar innan både intervjuer och användartester genomfördes. Deltagarna informerades även om att allt insamlat material endast delades inom forskningsgruppen och kommer att raderas när studien har godkänts. I studien säkerställdes konfidentialitet genom att personliga uppgifter, såsom namn, anonymiserats för att skydda deltagarnas integritet.

3.8 Användning av AI

I denna studie har AI använts som stöd i skrivprocessen. Specifikt har ChatGPT använts för språk- och struktur granskning av uppsatsens text, vilket har hjälpt att

identifiera grammatiska och språkliga fel som kan vara svåra att upptäcka manuellt. AI har inte använts för att generera innehåll, argument eller analyser och allt material är författarnas eget.

4. Resultat och analys

I detta kapitel presenteras deltagarnas uppfattning och resonemang kring designvarianterna av färg i studiens tre utformade gränssnitt. Här lyfts återkommande upplevelser, tankemönster och reflektioner som framkom under användartesterna. Syftet med resultatet är inte för att fastställa statistik signifikans, utan att ge en djupare förståelse för hur deltagarna upplevde tillit, identifiering av hallucinationer och overreliance i relation till de designvarianterna som undersöktes i studien.

4.1 Intervjuresultat

Intervjuresultaten presenteras här som underlag inför studiens kontext och målgrupp och ska inte tolkas som primära svar på studiens frågeställningar, den rollen fyller användartesterna i avsnitt 4.2.

4.1.1 Hälsorelaterad användning

Respondenterna uppgav att de använder ChatGPT för hälsorelaterade frågor, men hur ofta de använde det varierade tydligt mellan respondenterna (se tabell 2). Två respondenter uppgav en väldigt hög användning, där Sara beskrev verktyget som en “daglig rådgivare” och den andra använde det varannan till var tredje dag. Övriga respondenter uppgav en lägre frekvens på cirka en gång i veckan eller en gång i månaden.

Det mest förekommande användningsområdet var frågor om hälsorelaterade symtom och självdiagnos, men användning omfattade även områden såsom kost, mental hälsa samt allmänna hälsofrågor. Sara är en av respondenterna som

förklarar att användning mest sker till frågor kring kost och träning, men även vid mer hälsorelaterade symtom:

“Jag använder Chat till olika saker, men mest ställer jag frågor och ber om förslag om typ kost, hälsosamma måltider [...] även till träning [...] jag vänder mig till Chat när jag känner smärta eller har ont någonstans.” (Sara)

Anna visade också på ett liknande mönster där hon beskriver att hon direkt vänder sig till ChatGPT för alla symtom och även mental hälsa för att få diagnos av AI:n:

“Lite av allt, symtom och mental hälsa. [...] Om jag har ett utslag eller feber, eller om jag känner mig lite humörsam eller upplever hormonella förändringar. [...] Jag beskriver bara vad som händer med mig och ber det diagnostisera det.” (Anna)

Ett återkommande beteende hos två respondenter var att de medvetet formulerade sina frågor för att få mer precisa och personliga svar. Sara beskriver hur hon anpassar sin kommunikation med verktyget genom att inmata så mycket och detaljerat information som möjligt för att få mer specifika eller exakta svar:

“Jag brukar se till att jag formulerar mig så detaljerat som möjligt för att AI:n ska kunna ge mig ett mer exakt svar.” (Sara)

Karl beskriver ett liknande mönster där han är medveten om skillnaden när han skriver detaljerade frågor för att få mer personliga och utförliga svar jämfört med generella frågor:

“Jag tycker att ju mer information man bidrar med, desto mer specifikt svar kan man få. Då får man oftast ett mer preciserat svar om sitt tillstånd, till skillnad från om man skulle skriva något generellt, som till exempel “jag har ont i huvudet” (Karl)

Karl betonade att ChatGPT upplevdes som mer tillgängligt och snabbare än traditionella alternativ som vårdcentralen. Han beskriver hur han vänt sig till ChatGPT efter att ha upplevt vårdcentralens svar som otillräckliga, där han

upplevde att ChatGPT gav mer utförliga och konkreta svar jämfört med vårdcentralen:

"Jag brukar vända mig till Chat för det snabbast. Då kan Chat hjälpa till att bedöma om det är något allvarligt, icke-allvarligt och så vidare. Exempelvis ringde jag vårdcentralen för ett tag sedan, och då ville de inte hjälpa mig utan bara rekommenderade att jag skulle köpa en produkt, vilket inte hjälpte. Så jag vände mig till Chat, och då fick jag ett mer konkret och ingående svar på vad problemet faktiskt kan vara." (Karl)

4.1.2 Tillit och kritisk granskning

Respondenternas upplevelse av tillit till ChatGPTs hälsorelaterade svar varierade betydligt, vilket visas i tabell 3. Ett tydligt mönster är att de respondenter som dubbelkollar information också uppger källhänvisningar som den viktigaste faktorn för trovärdighet, medan de som inte dubbelkollar lägger mindre fokus på faktorer som skapar tillit.

Respondent	Upplevd trovärdighet	Dubbelkollar information	Faktorer som skapar tillit
Sara	Upplever svaren som trovärdiga, särskilt när källor anges	Ja, regelbundet	Referenser och källhänvisningar
Karl	Upplever svaren som trovärdiga men har även känt tvivel	Ja, vid viktiga frågor	Igenkänning från andra källor
Erik	Upplever inte svaren som trovärdiga	Nej	Litar redan på verktyget
Lina	Upplever svaren som orimliga och irrelevanta	Nej	Pålitliga källhänvisningar

Anna	Litar generellt på svaren utan att ifrågasätta dem	Nej	Litar redan på verktyget
Johan	Litar på svaren vid hälsofrågor men inte vid studierelaterade frågor	Ja, vid viktiga frågor	Kvalitet på referenser

Tabell 3: Respondenternas tillit och källkontroll

Sara och Karl visade den mest utvecklade kritiska granskningen och lyfte båda fram källhänvisningar som ett viktigt element för upplevd trovärdighet. Sara beskriver att faktorer som källhänvisningen, språk och ordval ökade hennes tillit till verktyget som jämfördes med hur en verklig läkare behandlar frågor:

"ChatGPT gav mig andra källor som den hänvisar till och det är det som gav mig mest tillit till AI:n. Men också hur den formulerar sitt svar, likaså de ordval som den använder. Det är väldigt likt vad en läkare skulle använda." (Sara)

Dessutom förklarar Karl:

"Jag tycker att informationen som jag fick var trovärdig, eftersom det är information som man har hört tidigare och det stämmer med andra typer av hemsidor och sajter som är pålitliga än ChatGPT, till exempel 1177. Dessutom hänvisade Chat till andra sidor direkt i svaret, och deras ikon med länk kom upp i gränssnittet, vilket gjorde att jag kände mer tillit till svaren." (Karl)

Trots att Karl ansåg informationen trovärdig uttryckte han att han ändå är källkritiskt och granskar informationen mot exempelvis 1177, framförallt när det gäller något han anser som allvarligt:

"Eftersom det gäller hälsorelaterade problem dubbelkollar jag verkligen informationen som ChatGPT ger mig. [...] jag brukar använda samma hemsidor som 1177 och andra legitima sidor för att

dubbelkolla information, särskilt när det gäller något viktigt och jag känner att det här kan vara allvarligare." (Karl)

Johan uppgav att han endast granskar information vid viktigare frågor och att tilliten varierar beroende på vad för område han söker om:

"Ja, det gör jag om det är något viktigt, men om det är något mindre viktigt brukar jag inte kontrollera det." (Johan)

Anna representerade ett annat beteende där overreliance visades tydligt, då respondenten uppgav att hon sällan dubbelkollar information:

"Nej, jag dubbelkollar vanligtvis inte, jag litar på det." (Anna)

Lina uppgav att svaren inte kändes trovärdiga eftersom ChatGPT upplevdes ge orimliga och irrelevanta förklaringar.

"Nej, det kändes inte trovärdigt. Det kändes som att ChatGPT inte riktigt förstod vad jag menade, och svaren upplevdes därför som orimliga. Den gav flera olika förklaringar som inte kändes relevanta." (Lina)

Ett undantag är Erik, som trots att han inte upplever svaren som trovärdiga uppgav att han ändå inte dubbelkollar informationen. När han frågade ChatGPT om sina ögonbesvär och fick ett svar han inte litade på valde han ändå att inte söka vidare:

"Nej, jag brukar inte kontrollera informationen, jag släppte det bara och gick vidare." (Erik)

4.1.3 Medvetenhet om hallucinationer

Respondenternas medvetenhet om ChatGPTs begränsningar varierade, vilket visas i tabell 4. Majoriteten kände till att ChatGPT kan ge felaktig information, men hur mycket varje hade förståelse för fenomenet skilde sig åt.

Respondent	Medvetenhet om	Har	Påverkar användning
------------	----------------	-----	---------------------

	felaktig information	upptäckt fel	
Sara	Ja	Ja	Ja, mer kritisk
Karl	Ja	Ja	Ja, undviker vissa frågor
Erik	Ja	Ja	Ja, begränsat förtroende
Lina	Nej	Nej	Ingen påverkan identifierad
Anna	Delvis	Nej	Nej
Johan	Ja	Ja	Delvis

Tabell 4: Respondenternas medvetenhet om hallucinationer

Lina var den enda respondenten som uppgav att hon saknade kunskap om fenomenet. Detta uttrycker hon genom att säga:

"Jag har ingen särskild kunskap om det." (Lina)

Samtidigt hade hon inte uppmärksammat någon felaktig information eller hallucinationer:

"Nej, det har jag inte lagt märke till." (Lina)

Detta skiljer sig från övriga respondenter som alla kunde ge konkreta exempel på tillfällen då de upptäckt fel eller ifrågasatt svaret. Sara beskrev hur medvetenheten om hallucinationer påverkat hur hon ser på verktyget och att det orsakat i att hon är mer kritisk mot svaren och att hon därför kontrollerar dem:

"Man blir lite mer kritisk mot svaren, och det kan förklara varför jag dubbelkollar dem. Däremot tycker jag att den allmänt ger bra information som mestadels är pålitlig, så jag skulle inte säga att jag använder Chat mindre, utan snarare att jag inte alltid tror blint på informationen den ger mig" (Sara).

Karl lyfte fram att han dessutom har blivit medveten om risker med okritisk användning efter medvetenheten om att verktyget kan ge felaktiga svar:

“[...] jag har också känt tvivel, eftersom man har sett på nyhetssajter att de varnar för att man inte ska tro blint på ChatGPT.” (Karl)

Både Erik och Johan uppgav att medvetenheten har gjort dem mer försiktiga i vilka typer av frågor de ställer till verktyget. Johan förklarar att han börjat vända sig till traditionella sajter för mer tillförlitliga svar:

"Vissa saker litar jag inte på att ChatGPT ska ge korrekt information om, till exempel viktigare skoluppgifter eller personlig information. [...] Då vänder jag mig till Google istället och söker på riktiga sajter som är legitimerade.” (Johan)

4.1.4 Gränssnittet och transparens

Svaren kring gränssnittet och transparens var de mest enhetliga av de fyra temana. Respondenterna uttryckte ett behov av visuella indikatorer för att visa osäkerhet i ChatGPTs svar, vilket framgår i tabell 5.

Respondent	Önskad designlösning	Visuellt element	Övrigt
Sara	Rankningssystem/ poängsystem	Färg (röd, orange, grön)	Kombination av flera lösningar
Karl	Skala med grader av säkerhet	Färg (röd, gul, grön)	Visuellt kombinerat med text
Erik	Indikator med text	Gul färg för osäkerhet, grön för säkert	Läkarbekaftelse
Lina	Verifierade källhänvisningar	Markering för verifierad info	-

Anna	Användarbetyg/ feedback	Behöver testa för att veta	Fråga hur mycket svaret hjälpte
Johan	Verifierade källhänvisningar	Behöver testa för att veta	Ej Wikipedia källor

Tabell 5: Respondenternas förslag på designlösningar

Ett återkommande mönster var preferensen för färgkodning som ett sätt att kommunicera tillförlitlighet. Sara föreslog ett kombinerat system där både nivåsystem och färger används för att kommunicera graden av osäkerhet:

"Något nivåsystem eller poängsystem som signalerar när den är säker eller osäker. Möjligtvis att det kan visualiseras med färger, så att exempelvis röd visar osäkerhet, orange visar något mittemellan och grön visar att svaret är säkert." (Sara)

Både Karl och Erik betonade att visuella element som färg behöver kombineras med text för att vara effektiva och för undvika att man hoppar över texten:

"Jag tycker att man inte bara ska visa detta i skrift, utan att det är viktigt att det kombineras med något visuellt, som till exempel färger, eftersom det är lätt att människor hoppar över att läsa texten." (Karl)

"Att ha en gul färg och en liten text där det står att det inte är 100 % säkert eller att det kan vara fel i svaret" (Erik)

Lina och Johan uppgav båda att de i stället önskar verifierade källhänvisningar som ett sätt att öka tillförlitligheten i svaren, där Lina påpekade att hon hade uppskattat hänvisningar till tillförlitliga källor eller även markering av säker text:

"Att få bekräftelse genom pålitliga källor, till exempel genom hänvisningar till relevanta webbplatser eller någon form av markering som visar att informationen är verifierad" (Lina)

4.1.5 Sammanfattning och analys av intervjuresultat

Intervjuerna visade att alla respondenter använder ChatGPT för hälsorelaterade frågor. Men hur ofta de använder ChatGPT samt deras tillit och kritiska granskning varierar. Dessutom visar intervjuerna att verktyget i vissa fall upplevs som ett likvärdigt eller till och med bättre alternativ än etablerade hälsokällor, såsom vårdcentralen, snarare än som ett komplement. Källhänvisningar och hur språket formuleras visades som de centrala faktorerna för upplevd trovärdighet. Medvetenheten om hallucinationer fanns hos respondenterna men påverkade inte alltid den kritiska granskningen av verktyget.

Det viktigaste bidraget från intervjuerna är att transparens om osäkerhet behöver vara inbyggd i gränssnittet och kommuniceras visuellt i stället för att enbart finnas tillgänglig för den som aktivt letar efter den. Flera respondenter uppgav ett behov av visuella element i gränssnittet där färgkodning tillsammans med text var den mest återkommande önskade lösningen. Hälften av respondenterna föreslog specifikt en färgkodning med färgerna röd, gul och grön som återspeglar AI-modellens säkerhetsstatus. Detta förstärker behovet av designvarianter som signalerar när ett svar bör ifrågasättas, oavsett om användaren själv upplever frågan som viktig eller inte.

4.2 Prototyptestning

Nedan presenteras resultatet från användartesterna. Deltagarna testade samtliga tre gränssnitt i Figma. Resultatet redovisas utifrån tre teman: läsbarhet och visuell tydlighet, förståelse av färgens kommunikativa funktion samt påverkan på kritisk granskning.

4.2.1 Gränssnitt 1

I gränssnitt 1 är all text markerad med färg, där grön färg visualiserar tillförlitlig och säker information medan röd färg visar osäker information. De flesta deltagarna upplevde gränssnittet som visuellt överväldigande och svårläst. Karl förklarar att färgen är för stark och kan därför distrahera från textinnehållet:

"Personligen upplever jag det som alldeles för överväldigande om hela svar ska vara helt färgmarkerade på det här sättet, nästan så att det distraherar från textinnehållet." (Karl)

Samma mönster beskrivs av Anna, Lina och Johan, där de upplevde texten som svårläst. Lina beskriver detta genom följande:

"Det kan bli lite för mycket när man tänker efter. För det blir svårt att läsa texten." (Lina)

Trots detta upplevde flera deltagare att färgkodningen var lätt att förstå konceptuellt. Lina uppgav att grönt och rött gav tydliga signaler om vad som var tillförlitligt respektive osäkert:

"Färgmarkeringarna gör det snabbt att tolka och förstå informationens trovärdighet. Jag förstår att grönt signalerar att informationen känns säker och tillförlitlig och att rött visar att informationen är osäker." (Lina)

Liknande uppfattning förklaras av Erik, där han upplevde det enkelt att förstå vad färgmarkeringen signalerade:

"Jag får tecken på vad som är tillförlitligt och vad som är mindre osäkert eftersom det är enkelt att förstå att det gröna är något som är godkänt, i detta fall att texten är tillförlitlig som även förklaras vid sidan av." (Erik)

Sara föreslog att gult borde användas istället för rött för att kommunicera osäkerhet, eftersom rött upplevdes som en för stark signal som kopplades med direkt felaktig information i stället för osäkerhet:

"Jag tycker överlag att det här fungerar bra, men jag skulle också vilja se att det används gult istället för rött. För mig signalerar rött mer av en varning, att något är helt fel eller inte tillförlitligt. Jag tycker att gult skulle då passa bättre för sådant som är osäkert eller"

behöver tolkas med försiktighet, medan grönt kan stå för tillförlitlig information.” (Sara)

Detta påpekar även Karl, som dessutom förklarar att han hade föredragit gult över röd färg:

“Däremot tycker jag att man inte borde använda rött, utan snarare gult för att markera osäker information. Jag förknippar rött med något negativt eller felaktigt, alltså att informationen är direkt fel. Gult känns mer som en varning om att något kan vara osäkert. ”
(Karl)

Johan upplevde gränssnittet som förvirrande vid första anblicken men förstod sedan färgmarkeringens funktion medan han läste igenom svaret. Han upplevde förvirring när han först introducerades till konceptet i gränssnitt 1:

“Blev lite förvirrad på det första gränssnittet, men tog in informationen och förstod.” (Johan)

När det gäller påverkan på den kritiska granskningen uppgav Erik att han inte hade dubbelkollat informationen eftersom gränssnittet tydligt visade vad som var tillförlitligt och vad som var osäkert:

“Jag hade faktiskt inte tänkt på att dubbelkolla informationen om jag ändå fått information på vad som är tillförlitligt och vad i svarstexten som är osäkert, dessutom med källan från 1177 vid sidan av. Kanske om det hade varit allvarlig symtom som jag hade känt mig mer orolig över så hade jag dubbelkollat och sökt information från andra håll också.” (Erik)

Dock uttryckte Karl en blandad upplevelse av konceptet där han uppskattade idén och blev uppmärksamrad om den osäkra informationen, men upplevde den visuella utformningen som för överväldigande:

“Jag gillar själva konceptet. Jag tycker om att färgerna visar vad som är trovärdigt och mindre trovärdigt. Men jag tror att det skulle fungera bättre för mig om det gjordes på ett annat sätt.” (Karl)

4.2.2 Gränssnitt 2

Gränssnitt 2 behöll den ursprungliga textens utseende men ändrade färgen på osäker information till grått, alltså en ljusare nyans av svart, medan tillförlitlig information behålls som svart. Resultaten för detta gränssnitt var mest enhetliga bland deltagarna.

Johan och Anna upplevde att visualiseringen var enkel att förstå, men båda uppgav att de förstod konceptet genom att läsa informationspanelen vid sidan av istället för texten för sig själv. Johan beskrev följande:

“Kanske om jag såg gränssnittet första gången hade jag inte förstått direkt vad den kommunicerar utan att se informationen bredvid.”
(Johan)

Lina och Erik upplevde däremot kontrasten mellan svart och grått som för svag för att vara tydlig. Lina beskrev följande:

“Det är svårt att urskilja vad som är tillförlitligt och vad som är osäkert eftersom skillnaderna mellan svart och grått upplevs för små. Kontrasten i texten är för svag.” (Lina)

Erik upplevde även otydlighet i färgmarkeringens roll utan informationen i sidopanelen:

“[...] och som sagt utan sidopanelen med information hade det varit svårt att förstå vad i texten som är mindre osäkert och vad som hade hög tillförlitlighet... jag tror också att det kan vara pga det snarlika kontrast i texten.” (Erik)

Erik uppgav att gränssnittet inte gav tillräckliga visuella signaler för att trigga kritisk granskning, och föredrog gränssnitt 1 av den anledningen. Sara kritiserade

gränssnittets otydlighet och föreslog att fetmarkering av tillförlitlig text skulle vara ett bättre alternativ än minskad färgmättnad för osäker text:

“Jag tänker också att ChatGPT ofta använder fetmarkering för att lyfta viktiga begrepp eller ord och i det här fallet vore det ett bättre alternativ att istället fetmarkera texten som har hög tillförlitlighet, i stället för att använda lägre färgmättnad. Problemet är att det blir svårt att urskilja vad som är viktigt och vad som är osäkert. Jag upplever det som otydligt”(Sara)

4.2.3 Gränssnitt 3

Gränssnitt 3 markerade enbart den osäkra informationen med röd färg och lämnade all övrig text i sitt ursprungliga utseende. Detta gränssnitt fick de mest positiva reaktionerna och föredrogs av majoriteten av deltagarna.

Både Karl och Sara uppgav att gränssnitt 3 var det bästa av de tre alternativen eftersom det behåller känslan av ett vanligt ChatGPT gränssnitt utan att överväldiga användaren. Karl beskriver:

"Det är skönt att slippa behöva hålla koll på många olika färger. Vanlig text är lättare att ta till sig, och man förstår direkt vad som är osäker information." (Karl)

Lina upplevde också att detta gränssnitt var tydligast och enklast att följa:

“Det är inte för mycket som händer här, det är enkelt att ta in. Det är två olika färger som gör det lätt att urskilja mellan. Tyckte att detta gränssnitt är tydligast, enklast att följa men också att förstå”(Lina)

Sara föredrog gränssnitt 3 över de andra, men föreslog att understrykning skulle kunna ersätta färgmarkeringen för att göra texten mer läsbar, samt att markera med gult i stället för rött:

“I stället vore det bättre att markera med understrykning. Om jag jämför med de andra alternativen tycker jag att den här versionen är bäst, eftersom det inte är för många färger som distraherar en, samtidigt som det är tydligt. [...] Optimalt skulle det kanske vara om man möjligtvis underströk hela texten med gult och grönt.” (Sara)

Anna jämförde gränssnitt 3 med de andra, där hon uttryckte att den var enklare att förstå utan kompletterande information, men att färgerna i gränssnitt 2 upplevdes mer minimala visuellt:

“Tyckte denna var bättre än första gränssnittet och tydligt att den rödmarkerade infon var osäker. Gränssnitt 2 är fortfarande enklare i sin visualisering och funkar bäst om infon bredvid finns. Dock var gränssnitt 3 enklare att förstå för sig själv utan infon bredvid.” (Anna)

Erik var ett tydligt undantag och föredrog gränssnitt 1. Han upplevde att enbart röd markering utan grön färg skapade osäkerhet kring övrig text:

“Eftersom det endast är röd färg på en del av svarstexten fick det mig att undra över övrig text i första anblicken, alltså de utan den röda färgen. Det gav mig en känsla att också de behöver verifieras.” (Erik)

När det gäller påverkan på kritisk granskning uppgav Anna att visualiseringen på osäkerhet skulle förändra hur hon tar in informationen från AI-genererade svar:

“Även om jag i allmänhet litar på ChatGPT hade det varit bra att kunna se detta i svaren. Om jag behöver kommer jag nog kolla upp den specifika informationen som är markerad, men jag kommer inte använda den osäkra informationen i alla fall.” (Anna)

4.2.4 Sammanfattning

Tabell 6 sammanfattar deltagarnas preferenser och upplevda påverkan på kritisk granskning per designvariant av färg.

Respondent	Föredragen designvariant	Motivering	Påverkan på kritisk granskning
Sara	Gränssnitt 3	Minst distraherande med tydlig markering	Skulle kolla upp specifik osäker information vid behov
Karl	Gränssnitt 3	Bäst balans mellan tydlighet och enkelhet	Skulle bli mer medveten utan att skapa onödig oro
Erik	Gränssnitt 1	Tydligast visuell signal om vad som är rätt och fel	Skulle inte dubbelkolla om gränssnittet visar vad som är tillförlitligt
Lina	Gränssnitt 3	Tydligast och enklast att följa	Uppmuntrar till källkritik
Anna	Gränssnitt 3	Bäst balans mellan tydlighet och enkelhet	Skulle kolla upp specifik osäker information vid behov
Johan	Gränssnitt 2	Renaste och mest lättläst	Skulle bli mer kritisk men inte nödvändigtvis dubbelkolla

Tabell 6: Deltagarnas preferenser och upplevda påverkan per designvariant

Sammanfattningsvis föredrogs gränssnitt 3 av fyra av sex deltagare, vilket gör det till den mest uppskattade designvarianten. Den största anledningen var att gränssnittet behåller känslan av ett vanligt ChatGPT-gränssnitt utan att överväldiga användaren, samtidigt som den röda markeringen tydligt signalerar vilken information som är osäker. Flera deltagare föreslog däremot att gult borde ersätta rött för att kommunicera osäkerhet istället för direkt felaktighet.

Gränssnitt 2 föredrogs av en deltagare och upplevdes som det renaste och mest lättlästa alternativet, däremot var gränssnittet otydlig i vad den ville kommunicera och blev beroende av informationen vid sidopanelen för att kommunicera sin funktion. Dessutom upplevdes kontrasten mellan svart och grått som för svag kontrast i färgens nyans.

Gränssnitt 1 föredrogs av en deltagare och upplevdes ha tydliga visuella skillnader mellan tillförlitlig och osäker information. Däremot upplevde majoriteten att det var visuellt överväldigande och svårläst, trots att idéns budskap uppfattades snabbt.

Gällande påverkan på kritisk granskning visade resultaten att designvarianterna ökade deltagarnas medvetenhet om osäker information i olika grad. Majoriteten av deltagarna uppgav att de skulle vara mer försiktiga i hur de använder AI-genererade svar när osäkerhet kommuniceras visuellt, även om inte alla uppgav att de aktivt skulle dubbelkolla informationen. Detta tyder på att färgvisualisering av osäkerhet kan minska overreliance utan att nödvändigtvis leda till aktiv granskning av informationen.

5. Diskussion

I detta kapitel diskuteras och tolkas studiens resultat kopplat till tidigare forskning och teori. Kapitlet inleds med en diskussion av intervjuresultaten och vad de bidrar med om målgruppens inställning till ChatGPT vid hälsorelaterade frågor. Därefter diskuteras användartesternas resultat och vad de innebär för hur färgdesign påverkar användarnas kritiska granskning och identifiering av hallucinationer i AI-genererade hälsorelaterade svar. Delen avslutas med en metoddiskussion där studiens styrkor och begränsningar reflekteras över samt som rekommendationer för framtida forskning ges.

5.1 Resultatdiskussion

5.1.1 Intervjuresultat

Att alla sex respondenter vänder sig till ChatGPT för hälsorelaterade frågor och att fyra av sex gör det flera gånger i veckan stödjer det mönster som Shahsavar & Choudhury (2023) och Guo et al. (2025) beskriver om den stora användning för symtomsökning och självdiagnostik.

Tidigare forskning beskriver overreliance som en tendens att okritiskt acceptera AI-genererade svar (Buccinca et al. 2021; Leiser et al. 2024). Intervjuerna visar detta mönster hos målgruppen, men lägger också till en viktig insikt: overreliance kan vara situationsbaserat för samma person i stället för ett fast beteende. Alltså kan samma användare vara kritisk vid en fråga hen upplever som viktig men samtidigt okritisk vid en annan. Anna visar overreliance genom att uppge att hon "litar på det" utan att dubbelkolla, medan Sara, Karl och Johan visar att granskning kan ske men är beroende av situationen. Detta mönster förklaras heller inte specifikt i automation bias (Zhao et al. 2025) som beskriver en generell tendens att lita på system istället för ett situationsbaserat beteende, men stärker behovet av designlösningar som signalerar osäkerhet oavsett om användaren själv upplever frågan som viktig eller inte.

Ett viktigt fynd är skillnaden mellan att känna till att ChatGPT kan ge felaktig information och att låta det faktiskt påverka beteendet. Sara uppger att hon blivit mer kritisk, men hennes användning är lika mycket och hon granskar bara vid frågor som hon upplever vara viktiga. Alltså har medvetenheten förändrat hennes syn på verktyget men inte hennes beteende. Liknande mönster syns hos Erik och Johan, medan Anna inte uppger någon förändring trots viss kännedom om fenomenet. Detta stärker behovet av transparens som är inbyggd direkt i gränssnittet, vilket ligger i linje med Liao & Vaughan (2024) som argumenterar för att ett AI-system som kommunicerar sin osäkerhet möjliggör för användaren att anpassa sin tillit, i stället för information som användaren aktivt måste söka upp.

I temat om designlösningar hade respondenterna mest lika svar. Hälften av respondenterna uttryckte självständigt, utan att känna till HILL, ett behov av färgkodning som visar hur säkert ett svar är. Detta stämmer väl överens med de designstrategier som identifierats i tidigare studier (Do et al. 2025; Leiser et al. 2024; Reyes et al. 2025). Däremot föredrog Lina och Johan verifierade källhänvisningar som en primär lösning, vilket inte är studiens fokus men förtjänar ändå att diskuteras.

Som beskrivs i avsnitt 2.1 baserar ChatGPT som standard sina svar på träningsdata och genererar inte vanligtvis källhänvisningar om detta inte efterfrågas (OpenAI 2026a). Detta är relevant eftersom Lina och Johan föredrog källhänvisningar som designlösning. Även när källor efterfrågas specifikt i prompten visar forskning att en stor majoritet av de genererade referenserna är hallucinerade (Bhattacharyya et al. 2023). Källhänvisningar är därmed inte en tillförlitlig lösning för att öka transparens och kan även bidra med ytterligare hallucinationer, vilket strider mot studiens syfte. Däremot visar andra verktyg som Perplexity AI att källhänvisningar i realtid är tekniskt möjliga (Perplexity Team 2023), men detta är inte hur ChatGPT fungerar som standard och är därmed inte en lösning som är tillgänglig för de flesta användare idag.

Intervjuresultat bidrar med ett underlag inom studiens kontext som belyser målgruppens relation och beteende till ChatGPT samt deras behov av transparens, dock är det användartesternas resultat som utgör studiens centrala empiriska bidrag och som besvarar studiens frågeställningar.

5.1.2 Användartester

Resultaten från användartesterna visar att färgvisualisering av osäkerhet i ChatGPTs gränssnitt påverkade deltagarnas kritiska granskning av AI-genererade hälsosvar, och att gränssnitt 3, som enbart markerade osäker information med röd färg, föredrogs av fyra av sex deltagare. Nedan tolkas vad dessa resultat innebär, hur de relaterar till tidigare forskning och vad det betyder för framtida utvecklingar inom design.

Resultaten visar att de olika designvarianterna ökade deltagarnas medvetenhet om osäker information, men att denna medvetenhet inte automatiskt ledde till att de aktivt dubbelkollade informationen. Majoriteten uppgav att de skulle vara mer kritiska och selektiva i hur de använder AI-genererade svar istället för att lita blint på det, men inte nödvändigtvis söka upp dem utanför verktyget om det inte är relevant för situationen. Detta är en viktig insikt eftersom det tyder på att färgvisualisering påverkar hur användaren tar emot och använder informationen, men att det inte alltid är tillräckligt för att leda till källkritiskt beteende. Detta bygger på det mönster som visades i intervjuerna om situationsbaserad overreliance, och stödjer Buccinca et al. (2021) som argumenterar för att designlösningar behöver aktivt stödja analytiskt tänkande och att enbart kommunikation av osäkerhet räcker inte för att fullt ut förändra beteendet. Samtidigt bidrar studien med insikten att även om färgvisualisering av osäkerhet inte är tillräckligt för att helt påverka beteendet kan det minska overreliance genom att ändra på hur användaren ser och litar på informationen.

Resultaten visar en tydlig skillnad mellan visuell tydlighet och läsbarhet som är viktig för hur designvarianter av färg bör utformas. Gränssnitt 1, som färgkodade all text baserat på highlight-all-strategin från Do et al. (2025), uppfattades snabbt idémässigt men upplevdes som överväldigande att läsa. Detta är i linje med Do et al. (2025) som visade att Highlight-all var den mest föredragna strategin i deras studie, men påpekade att längre färgmarkerade svar kan bli problematiskt. Till skillnad från deras studie var denna strategi den minst föredragna, vilket kan bero på att ett hälsorelaterat svar är längre och mer informationsrikt än de kortare frågor och svar som Do et al. (2025) använde. Gränssnitt 2, som följer färgmättnad enligt Boukhelifa et al. (2012), upplevdes som lättläst men otydligt i dess syfte utan kompletterande förklaring. Detta tyder på att gränssnitt 2 är beroende av sidopanelen för att tydliggöra sin funktion och kan därför inte stå för sig själv för att självständigt kommunicera osäkerhet. Trots att Boukhelifa et al. (2012) rekommenderar mättnad som den mest intuitiva lösningen för att visualisera osäkerhet, tyder resultaten av denna studien på att kontrasten mellan svart och grått inte är tillräcklig stark för att självständigt kommunicera osäkerhet

utan kompletterande information vid sidan. Gränssnitt 3 balanserade dessa aspekter bäst, vilket pekar mot att selektiv markering av enbart osäker information är en mer lättläst och intuitiv strategi i en hälsorelaterad kontext än fullständig färgkodning, ett fynd som kompletterar Do et al. (2025), vars studie inte specifikt undersökte hälsorelaterade sammanhang.

Ett oväntat men intressant mönster var att flera deltagare spontant föreslog gult istället för rött för att kommunicera osäkerhet och ytterligare förbättra läsbarheten, eftersom rött kopplades direkt till felaktig information snarare än osäkerhet. I en hälsorelaterad kontext är denna distinktion viktig eftersom målet inte är att visa att informationen är helt fel utan att signalera att den bör granskas kritiskt. Boukhelifa et al. (2012) lyfte fram att färgnyanser kommunicerar olika grader av osäkerhet och att färgvalet påverkar tolkningen av informationens status, vilket stödjer deltagarnas reaktion. Detta innebär att färgvalet inte bara är en estetisk fråga men också ett kommunikativt designbeslut med direkt påverkan på hur användaren ser på informationen.

Detta är också centralt för hur färgmarkering bör förstås i denna studie. ChatGPT har inte förmågan att känna till när den genererar felaktig information, alltså producerar modellen svar baserat på sin träningsdata utan att kunna verifiera faktapåståenden (Ji et al. 2023). Tekniskt är det därför inte möjligt att verktyget med säkerhet kan visa vilken information som är hallucinerad, och färgmarkeringen kan därmed enbart fungera som en riskindikator som visar vilken information som är potentiellt osäker och bör granskas kritiskt. Detta stärker ytterligare argumentet för att gult, som signalerar varning och osäkerhet, är ett mer lämpligt färgval än rött, som signalerar fel.

Eriks preferens för gränssnitt 1 väcker en viktig designutmaning. Han upplevde att den röda markeringen i gränssnitt 3 skapade osäkerhet kring den omarkerade texten, där han undrade om även den behövde granskas. Det är värt att notera att Eriks preferens för gränssnitt 1 inte grundades i läsbarhet, utan i att färgkodning av all text gav tydliga signaler om vad som var tillförlitligt och vad som var osäkert, vilket selektiv markering inte gav på samma sätt. Detta visar att framtida

designvarianter bör undersöka om en kombination av selektiv markering av osäker information med ett tydligare visuellt stöd för vad som är tillförlitligt utan att färgkoda all text, kan uppfylla båda behoven.

Resultaten bidrar med flera insikter om design för transparens i AI-gränssnitt. De visar att färgvisualisering är en lovande strategi för att minska overreliance och öka medvetenheten om hallucinationer i hälsorelaterade AI-svar, vilket ligger i linje med vad Liao & Vaughan (2024) och Armstrong et al. (2025) argumenterar för gällande vikten av transparens i AI-gränssnitt. Reyes et al. (2025) visar dessutom att visualisering av osäkerhet påverkar hur användare anpassar sin tillit till AI, vilket stödjer att färgmarkering kan ha en meningsfull effekt även när den inte leder till aktiv dubbelkoll. Resultaten pekar också mot att designvarianter behöver anpassas till kontexten, där i en hälsorelaterad kontext är enkelhet och läsbarhet lika viktigt som visuell tydlighet.

Sammanfattningsvis bidrar användartester med tre viktiga insikter. Först visar de att overreliance är situationsbaserat snarare än ett fast beteende, vilket skiljer sig från hur fenomenet beskrivs i tidigare forskning. Ytterligare visar de att selektiv färgmarkering av enbart osäker information är en tydligare och mer läsbar strategi än fullständig textkodning i en hälsorelaterad kontext. Dessutom introducerar studien begreppet riskindikator som ett mer relevant sätt att beskriva färgmarkeringens funktion i AI-gränssnitt, givet att ChatGPT inte kan bekräfta vilken information som är hallucinerad.

5.2 Metoddiskussion

Genom förstudiens kvalitativa djupintervjuer och användartester, observationer samt think-aloud, insamlades värdefulla data som synliggjorde både vad deltagarna uttryckte och hur de reagerade. Att samma användare deltog i både intervjuerna och användartester möjliggjorde jämförelser mellan deras förväntningar och faktiska upplevelser. Den kontrollerade outputen, där två felaktiga påståenden fakta kontrollerades mot 1177 (2023), tillät alla användare att möta samma information och gav därför en konsekvent upplevelse som gav möjlighet för fokuset att ligga på designlösningar och upplevelsen av det. Denna

metod följer Do et al. (2025) och stärkte våra resultat i studien. Dock innebär denna metod att resultaten inte direkt kan tolkas till en verklig situation och användning, eftersom svarens längd och innehåll i ChatGPT varierar.

Ytterligare avgränsades studien till att utforska designelementet färg eftersom det är ett av de fem designelement som HILL-studien (Leiser et al. 2024) identifierade som mest betydelsefull bland användarna samt det mest lämpliga elementet att utforska vidare utifrån denna studies syfte. Avgränsningen möjliggjorde en fördjupad analys av hur olika varianter av färg påverkar användaren och kunde därmed även bygga vidare på tidigare studiers resultat. Buccinca et al. (2021) påpekar att deras resultat behöver undersökas i olika kontexter, vilket stärker relevansen av att denna studie specifikt undersöker en hälsorelaterad kontext där konsekvenserna av overreliance kan vara allvarliga.

En begränsning är att studien genomfördes med sex deltagare inom målgruppen, vilket är vanligt i kvalitativa studier. Dock kan detta begränsa hur överförbara resultaten är, alltså i vilken grad resultaten är relevanta för andra kontexter och åldrar än en hälsorelaterad kontext och mellan 18-29 år. Resultaten bör därför tolkas som en empirisk grund som kan byggas på i stället för slutsatser som representerar en bredare publik. Dessutom är det värt att diskutera att studien baseras på ett bekvämlighetsurval, vilket kan ha begränsat mångfalden i deltagarnas perspektiv. Detta innebär en risk för social önskvärdhet i svaren, vilket i sin tur kan ha påverkat studiens resultat och trovärdighet. För att minska denna risk togs flera åtgärder under datainsamlingen, som beskrivs i avsnitt 3.3.2. Trots dessa åtgärder kan risken för social önskvärdhet inte helt uteslutas, och tolkningen av resultaten bör därför göras med en viss försiktighet.

Ytterligare är en annan begränsning att deltagare testade gränssnitt i samma ordning, vilket kan ha påverkat resultaten och deras förståelse för varje gränssnitt. Detta illustreras tydligt av Johan, som uppgav att han troligen inte hade förstått gränssnitt 2 utan kompletterande information om han sett det som det första gränssnittet, vilket innebär att tidigare upplevelse av ett gränssnitt kan underlätta förståelsen av ett annat. I framtida studier bör därför ordningen varieras mellan

deltagare för att kunna få en större förståelse för hur varje gränssnitt kan stå för sig själv och hur deltagarna upplever varje gränssnitt utan att ha sett eller tagit in ett annat gränssnitt innan.

Denna studie tog inte hänsyn till individer med färgblindhet och gränssnitt 1 som har all text markerad med både grönt och rött kan vara svårt för användare med färgblindhet att urskilja. Detta stärker dock valet av gränssnitt 3 som var den mest föredragna, eftersom enbart den felaktiga informationen är markerad med rött, vilket kan göra det enklare för individer med färgblindhet att upptäcka. Flera deltagare föreslog dessutom spontant gult som färg istället för rött, vilket tyder på att färgvalet är en viktig faktor som är värd att undersöka vidare. Framtida designutveckling bör därför beakta tillgängligheten för användare med nedsatt färgseende.

Det är även värt att nämna att studiens avgränsning till enbart färg borde ha kommunicerats tydligt i intervjuerna och användartester eftersom flera deltagare lyfte spontant fram önskemål om källhänvisningar som en lösning i gränssnittet. Detta påverkade inte användartesternas resultat direkt eftersom testerna genomfördes med specifika prototyper och en kontrollerad miljö, men kan ha påverkat deltagarnas svar i intervjuerna.

Slutligen, så redogörs hur ChatGPT tillämpats för språk- och strukturgranskning av uppsatsens text i avsnitt 3.8. Detta kan innebära en viss påverkan på hur texten är formulerad och strukturerad, även om innehållet och analyserna är författarnas egna. En risk med att använda AI för språkgranskning är att verktyget ibland omformulerar meningar på ett sätt som förändrar originalspråket. För att minska denna risk granskades alla AI-föreslagna ändringar av författarna innan de godkändes.

6. Slutsatser

Denna studie undersökte hur olika sätt att implementera färg som designelement i ChatGPTs gränssnitt påverkar användares kritiska granskning av hälsorelaterade

AI-genererade svar, samt vilken designvariant användarna föredrar för att identifiera hallucinationer och minska overreliance.

Frågeställning 1: *Hur påverkar olika sätt att implementera färg som designelement i ChatGPTs gränssnitt användarnas kritiska granskning av hälsorelaterade AI-genererade svar vid symtomsökning och självdiagnostik?*

Resultaten visar att designvarianterna ökade användarnas medvetenhet om osäker information, men att denna medvetenhet i sig inte ledde till aktivt källkritiskt beteende. Färgvisualisering påverkade främst hur användarna värderade och använde informationen snarare än att direkt få dem att dubbelkontrollera innehållet. Detta tyder på att färg kan fungera som ett verktyg för att minska overreliance utan att nödvändigtvis förändra beteendet helt.

Frågeställning 2: *Vilken designvariant för färg föredrar användarna för att identifiera hallucinationer och minska overreliance på AI?*

Resultaten visade att majoriteten av deltagarna föredrog gränssnitt 3, som enbart markerade osäker information med röd färg, eftersom designvarianten upplevdes som tydligast och mest lättläst. Dessutom framkom att färgvalet bör undersökas vidare, då flera deltagare föreslog gult i stället för rött eftersom gult kommunicerar osäkerhet snarare än direkt felaktighet. Denna skillnad är viktig eftersom färgmarkering i detta sammanhang fungerar som en riskindikator snarare än en felindikator, då ChatGPT inte kan bekräfta vilken information som faktiskt är hallucinerad.

6.1. Fortsatt forskning

Framtida studier bör inkludera ett större urval för att stärka överförbarheten av resultaten. Vidare bör olika färgval, exempelvis gult i stället för rött, undersökas för att avgöra vilket som bäst kommunicerar osäkerhet i en hälsorelaterad kontext. Dessutom bör tillgänglighet för användare med färgblindhet också beaktas i framtida designutveckling. Slutligen är det värdefullt att undersöka om en

kombination av färgvisualisering och källhänvisningar ger en starkare effekt på kritisk granskning än färg ensamt.

7. Efterord: deltagarnas bidrag

Denna studie hade inte varit möjlig utan de sex deltagare som tog tiden att dela sin upplevelse, tankar och reflektioner. Genom sina svar i intervjuerna bidrog de med värdefull förståelse för hur och när unga vuxna använder ChatGPT vid hälsorelaterade frågor. Under användartesterna delade de öppet sina reaktioner och upplevelser av de olika designvarianterna, vilket ledde till studiens empiriska underlag.

Vi tackar därför för deras engagemang och ärlighet, då de gav oss en förståelse för hur designlösningar för AI-transparens kan upplevas i praktiken. Deras bidrag möjliggjorde studiens resultat och vi hoppas att denna studie kan vidare bidra till utvecklingen av AI-gränssnitt som bättre stödjer användare i att kritiskt granska hälsorelaterad information. Slutligen vill vi rikta ett stort tack till Kerstin Ådahl för värdefull handledning, stöd och vägledning under arbetets gång.

Referenser

Armstrong, H., Anderson, A.L., Planchart, R., Baidoo, K. & Peterson, M. (2025). Addressing uncertainty in LLM outputs for trust calibration through visualization and user interface design. *Visible Language*. 59(2), s. 176–217.
<https://journals.uc.edu/index.php/vl/article/view/8934/7112> (2026-03-04)

Benyon, D. (2019) *Designing User Experience: A Guide to HCI, UX and Interaction Design*. 4th edn. Harlow: Pearson.

Bhattacharyya, M., Miller, V. M., Bhattacharyya, D., Miller, L. E. (2023). High rates of fabricated and inaccurate references in ChatGPT-generated medical content. *Cureus*, 15(5). doi: [10.7759/cureus.39238](https://doi.org/10.7759/cureus.39238) (2026-03-04)

Boonstra, L. (2025). *Prompt Engineering*. Google.
<https://drive.google.com/file/d/1ADc-526c7F42reuF6lKAetGUy6X-kylH/view>
 (2026-04-09)

Boukhelifa, N. Bezerianos, A. Isenberg, T. Fekete, D. (2012). Evaluating sketchiness as a visual variable for the depiction of qualitative uncertainty. *IEEE Transactions on Visualization and Computer Graphics (TVCG)*. 18(12), 2769-2778. <https://doi.org/10.1109/TVCG.2012.220> (2026-02-22)

Buccinca, Z., Malaya, M.B. & Gajos, K.Z. (2021). To Trust or to Think: Cognitive Forcing Functions Can Reduce Overreliance on AI in AI-assisted Decision Making. *Proceedings of the ACM on Human-Computer Interaction*. 5(CSCW1). <https://doi.org/10.1145/3449287> (2026-04-11)

Cerino, L., Felts, A., Balmuth, A., Brennan, T., Lee, C. & Coughlin, J. (2025). Older Adults' Perspectives on Artificial Intelligence as a Source of Advice. *Innovation in Aging*. 9(2). <https://doi.org/10.1093/geroni/igaf122.1371>
 (2026-05-19)

Do, H. J., Ostrand, R., Geyer, W., Murugesan, K., Wei, D. and Weisz, J. (2025) "Highlight All the Phrases: Enhancing LLM Transparency Through Visual

Factuality Indicators”, *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*, 8(1), pp. 772-784. [doi: 10.1609/aies.v8i1.36588](https://doi.org/10.1609/aies.v8i1.36588). (2026-02-19)

Guo, S., Song, Y., Chen, G., Han, H., Wu, H. & Ma, J. (2025). Promoting trust and intention to adopt health information generated by ChatGPT among healthcare customers: An empirical study. *Digital Health*, 11:20552076251374121. <https://doi.org/10.1177/20552076251374121> (2026-02-19)

Gravel, J., D’Amours-Gravel, M. och Osmanlliu, E. (2023). Learning to fake it: Limited responses and fabricated references provided by ChatGPT for medical questions. *Mayo Clinic Proceedings: Digital Health*, 1(3), s. 226–234. <https://doi.org/10.1016/j.mcpdig.2023.05.004> (2026-02-27)

Göteborgs universitet (u.å.). *Att söka information*. <https://studentportal.gu.se/service-och-stod/guide-till-att-soka-lasa-och-skriva/att-soka-information> (2026-03-04)

HKDIR (u.å.). *Kanalsök - tidskriftsregister*. <https://kanalregister.hkdir.no/sok?option=journals&input=> (2026-03-16)

Hu, K. (2023). *ChatGPT sets record for fastest-growing user base – analyst note*. Reuters. <https://www.reuters.com/technology/chatgpt-sets-record-fastest-growing-user-base-analyst-note2023-02-01/> (2026-03-04).

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y.J., Madotto, A. & Fung, P. (2023). Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, 55(12). <https://doi.org/10.1145/3571730> (2026-04-18)

Karolinska Institutet Universitetsbiblioteket (u.å.). *Värdera och granska källor*. <https://kib.ki.se/soka-vardera/vardera-och-granska-kallor> (2026-03-16)

Leiser, F., Eckhardt, S., Leuthe, V., Knaeble, M., Maedche, A., Schwabe, G. & Sunyaev, A. (2024). HILL: A Hallucination Identifier for Large Language Models. *CHI '24: Proceedings of the 2024 CHI Conference on Human Factors in*

Computing Systems. s.1-13. <https://doi.org/10.1145/3613904.3642428>
(2026-02-22)

Liao, Q.V. and Wortman Vaughan, J. (2024) 'AI Transparency in the Age of LLMs: A Human-Centered Research Roadmap', *Harvard Data Science Review*, (Special Issue 5). [doi:10.1162/99608f92.8036d03b](https://doi.org/10.1162/99608f92.8036d03b). (2026-04-09)

Liu, B. & Chilton, L. (2022) Design Guidelines for Prompt Engineering Text-to-ImageGenerative Models. *Proceedings of the ACM Conference, ACM*. <https://doi.org/10.1145/3491102.3501825> (2026-03-04)

Liu, Y. & Wang, H.(2024). Who on Earth Is Using Generative AI?. Policy Research Working Paper 10870. *World Bank Group, Digital Development Global Practice*.
<https://documents1.worldbank.org/curated/en/099720008192430535/pdf/IDU-5f321eb5-4870-472d-a888-3ab677be07b0.pdf> (2026-03-03)

Löwgren, J. (2015). *Till en designstudent som ska göra examensarbete på kandidatnivå*. https://jonas.lowgren.info/Material/kand_design_kompendium.pdf
(2026-02-08)

Martin, B. & Hanington, B. (2016). *Universal methods of design : 100 ways to research complex problems, develop innovative ideas, and design effective solutions*. Beverly, Mass. : Rockport

OpenAI. (2026a). *Does ChatGPT tell the truth?*
<https://help.openai.com/en/articles/8313428-does-chatgpt-tell-the-truth>
(2026-02-16)

OpenAI. (2026b). *Introducing ChatGPT Health*. [Introducing ChatGPT Health | OpenAI](https://openai.com/research/introducing-chatgpt-health) (2026-03-19)

Perplexity Team. (2023). *Introducing PPLX online LLMs*.
<https://www.perplexity.ai/hub/blog/introducing-pplx-online-llms> (2026-05-09)

- Patel, R. och Davidson, B. (2019). *Forskningsmetodikens grunder: att planera, genomföra och rapportera en undersökning*. 5:e uppl. Lund: Studentlitteratur (2026-05-09).
- Reyes, J., Batmaz, A. U. & Kersten-Oertel, M. (2025). Trusting AI: does uncertainty visualization affect decision-making? *Frontiers in Computer Science*. 7. <https://doi.org/10.3389/fcomp.2025.1464348> (2026-04-09)
- Shahsavar, Y. & Choudhury, A. (2023). User Intentions to Use ChatGPT for Self-Diagnosis and Health-Related Purposes: Cross-sectional Survey Study. *JMIR Human Factors* 10 (e47564). doi: [10.2196/47564](https://doi.org/10.2196/47564) (2026-03-05)
- Sveriges riksdag (2003). *Lag (2003:460) om etikprövning av forskning som avser människor*. https://www.riksdagen.se/sv/dokument-och-lagar/dokument/svensk-forfattningssamling/lag-2003460-om-etikprovning-av-forskning-som_sfs-2003-460/ (2026-03-06)
- Tjora, A. (2012). *Från nyfikenhet till systematisk kunskap: kvalitativ forskning i praktiken*. Studentlitteratur.
- Umeå universitet (u.å.). *Fördjupade sökmetoder*. <https://www.umu.se/bibliotek/soka-skriva-studera/informationssokning-och-kallkritik/fordjupade-sokmetoder/> (2026-03-04)
- World Health Organization. (2025). *Health Literacy*. <https://www.who.int/news-room/fact-sheets/detail/health-literacy> (2026-03-04)
- Zhao, R., Zhu, F., Han, J. & Hu, S. (2025). Visual Perception Uncertainty Learning for Hallucination Detection in Large Vision-Language Models. MM '25: *Proceedings of the 33rd ACM International Conference on Multimedia*. s. 3595-3604. <https://doi.org/10.1145/3746027.3755126> (2026-02-22)
- Zimmerman, J., Forlizzi, J. & Evenson, S. (2007). Research through design as a method for interaction design research in HCI. *CHI '07: Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*. s. 493–502. <https://doi.org/10.1145/1240624.1240704> (2026-04-09)

1177. (2023). *Sömnsvårigheter*. 1177 Vårdguiden.

<https://www.1177.se/Skane/liv--halsa/stresshantering-och-somn/somnsvarigheter/>

(2026-04-22)

Bilagor

BILAGA 1 - Intervjuguide

Följande intervjuguide användes vid de kvalitativa djupintervjuer som genomfördes under mars 2026.

Fas 1: Uppvärmningsfrågor

- Hur gammal är du och vad studerar/jobbar du med?
- Hur länge har du använt ChatGPT ungefär?
- Vad använder du ChatGPT till i vardagen?
- Har du någon gång använt ChatGPT för frågor som rör hälsa? (Om ja: Hur ofta ungefär?)

Fas 2: Reflexionsfrågor

Tema 1 - Hälsorelaterad användning

- Vilken typ av hälsofrågor ställer du vanligtvis till ChatGPT. Handlar det exempelvis om symptom, mediciner, mental hälsa eller något annat?
- Kan du beskriva ett tillfälle då du använde ChatGPT för att söka information om symptom eller hur du mår?

Tema 2 - Tillit och kritisk granskning

- Kan du beskriva hur du reagerade på svaret du fick, kändes det trovärdigt?

Tema 3 - Medvetenhet om hallucinationer

- Kan du beskriva vad du vet om att ChatGPT ibland kan ge felaktig information?

Tema 4 - Gränssnittet och transparens

- Kan du beskriva om det är något i hur ChatGPT presenterar sina svar som påverkar hur du uppfattar dem?

Fas 3: Avrundningsfrågor

- Om du fick önska något som skulle göra det lättare att bedöma om ett hälsorelaterat svar från ChatGPT är tillförlitligt - vad skulle det vara?
- Är det något du vill tillägga eller fråga om?